

몰입형 XR을 위한 상황 인식 기반 Adaptive Passthrough Framework

Context-aware Adaptive Passthrough Framework for Immersive XR



팀명: Team VR

202355532 따다소 thadarsoe730@pusan.ac.kr

202355667 최아영 ayoun0421@pusan.ac.kr

202155583 이승주 maya0108@pusan.ac.kr

지도교수: 이명호 교수님

제출일: 2026년 09월 11일

부산대학교

목차

1	서론	1
1.1	연구 배경	1
1.2	기존 문제점	2
1.3	연구 목표	2
1.3.1	페르소나 기반 유즈케이스 시나리오	2
2	연구 배경	5
2.1	기존 VR 안전 시스템 및 Passthrough 기술 현황	5
2.1.1	Meta Quest Guardian과 Smart Guardian	5
2.1.2	Passthrough 기술과 Passthrough Camera API	6
2.1.3	Apple Vision Pro의 경계 시스템	6
2.1.4	기타 플랫폼(PICO, HTC Vive) 및 공통적 한계	6
3	연구 내용	7
3.1	본 연구의 차별성	7
3.1.1	위험 판단 기준	7
3.1.2	대응 대상	7
3.1.3	제어 방식	7
3.1.4	노출 범위	8
3.1.5	사용자 개입 필요성	8
3.2	이전 보고서 기반 설계 변경 사항	8
3.2.1	변경 사유	9
3.2.2	변경된 설계	9
3.3	시스템 계층별 구조 및 역할	11
3.3.1	하드웨어 및 입력 계층 (Hardware & Input Layer)	11
3.3.2	이중 독립 위험 분석 엔진 (Dual Independent Processing Engine)	11
3.3.3	상위 개인화 제어 계층 (Upper Control Layer / Personalization)	13

3.3.4 렌더링 및 출력 계층 (Rendering & Output Layer)	13
3.4 정적, 동적 경계의 역할과 정보 흐름	13
3.4.1 공통 처리 순서	13
3.5 정적 경계의 측정 대상과 표본 배치	14
3.5.1 수치를 읽는 기준	14
3.5.2 입력 정보와 측정 방법	14
3.5.3 자기 몸과 바닥을 제외하는 원리	16
3.6 정적 경계의 거리 계산과 평활화	16
3.6.1 유한한 장애물까지의 거리	17
3.6.2 깊이 표본의 군집과 시간 평활화	17
3.7 정적 경계의 측정 결합과 신뢰도	18
3.7.1 두 종류의 거리 선택	18
3.7.2 깊이 관측의 품질 지표	18
3.8 정적 경계의 접근 속도와 TTC	19
3.8.1 위치 변화에서 접근 속도 구하기	19
3.8.2 거리 감소율과 신체 움직임의 결합	19
3.9 정적 경계의 위험 판단	20
3.9.1 머리와 낮은 장애물	20
3.9.2 왼손과 오른손	20
3.10 정적 경계의 경고 시작과 해제	21
3.10.1 일반 위험의 시작과 해제 기준	21
3.10.2 최소 유지와 해제 지연	21
3.10.3 머리 주변의 안전 체적과 긴급 조건	22
3.11 정적 경계의 표면 창과 방향 표현	22
3.11.1 장애물 표시 평면의 생성과 안정화	22
3.11.2 거리와 시야각으로 창 크기 결정	22
3.11.3 표시 우선순위와 보조 경고	23
3.12 동적 경계의 영상 측정과 사람 연결	23
3.12.1 입력 정보와 바운딩박스	23
3.12.2 같은 사람의 관측을 연결하는 원리	24
3.13 동적 경계의 깊이 측정과 거리 가공	24
3.13.1 촬영 시점과 깊이 광선을 맞추는 방법	24
3.13.2 사람 내부의 깊이 표본과 군집	25

3.13.3 군집 선택과 시간적 일관성	25
3.14 동적 경계의 상대 접근과 TTC 추정	25
3.14.1 거리 이력에서 상대 속도 구하기	26
3.14.2 깊이가 부족할 때 영상 크기로 대체	26
3.15 동적 경계의 위험 성분과 결합	27
3.15.1 네 가지 위험 성분	27
3.15.2 합성 위험과 근거리 하한	28
3.16 동적 경계의 경고 유지와 해제	28
3.16.1 일반 경고	28
3.16.2 초근거리 강제 표시	28
3.17 동적 경계의 사람 표시 영역	29
3.17.1 사람 중심의 계산과 위치 보정	29
3.17.2 상체 캡슐형 창 의 위치와 크기	30
3.17.3 깊이가 없을 때의 표시 위치	30
3.18 공통 Passthrough 표현 원리	30
3.18.1 양쪽 눈에 맞춘 공간 정렬	30
3.18.2 현실 영상을 드러내는 합성	31
3.18.3 시선을 유도하는 보조 경고	31
3.19 개인화 모듈의 전체 구조	32
3.20 PC에서의 모델 학습	33
3.20.1 학습 데이터의 단위	33
3.20.2 라벨링 규칙과 그 설계상 한계	33
3.20.3 입력 특징 벡터	34
3.20.4 모델 학습	34
3.21 Unity에서 실행 가능한 형태로의 변환	35
3.22 Quest 내부에서의 임계값 조정	36
3.22.1 조정 대상 임계값과 기본값	36
3.22.2 보정치 δ 의 계산	36
3.22.3 추론 시점과 주기	37
3.22.4 콜드스타트 처리	37
3.22.5 Shadow Mode: 세 가지 독립 조건	37
3.22.6 안전장치 요약	38
3.22.7 현재 구현의 한계	38

4	연구 결과 분석 및 평가	40
4.1	연구 방법	40
4.1.1	실험 환경	40
4.1.2	실험 설계	41
4.1.3	측정 도구	43
4.2	분석 방법	44
4.3	결과	45
4.4	논의	47
4.5	한계점	48
5	결론 및 향후 연구 방향	49
5.1	향후 연구 방향	49
5.2	결론	49
6	기타	51
6.1	개발 일정 및 역할 분배	51

제1장 서론

1.1 연구 배경

XR 시장은 2021년 약 190억 달러에서 2026년 약 1,008억 달러 규모로 연평균 39.7% 성장 이 예측되며[1], XR 기기의 보급 또한 빠르게 확대되고 있다. Head-Mounted Display(HMD) 기반의 몰입형 VR 환경에서는 사용자가 가상환경에 집중하는 동안 현실 공간에 대한 시각적 인지가 제한되어 주변 장애물이나 공간 경계와 충돌할 위험이 발생할 수 있다[2]. 따라서 가상환경에서의 몰입감을 유지하면서도 현실 공간의 장애물과의 충돌을 방지할 수 있는 안전 기술이 중요한 과제로 대두되고 있다.

그러나 Meta Quest의 Guardian은 사용자가 설정한 경계선에 근접하면 경계 그리드를 표시하는 방식으로 안전을 확보하는데 [3], 이 방식은 공간이 협소하거나 벽에 인접한 환경에서 사용자 의도와 무관하게 경계 그리드를 지나치게 빈번히 표시하여 몰입감을 저해할 수 있다. 또한 모든 사용자에게 동일한 임계값을 적용하여, 안전과 몰입감에 대한 개인별 선호 차이를 반영하지 못한다. Guardian 시스템의 구체적인 동작 방식과 한계는 2장에서 자세히 다룬다.

2025년 공개된 Passthrough Camera API는 Quest 3/3S 전방 카메라를 활용한 컴퓨터 비전, ML 파이프라인 구성을 가능케 했으나[4], 이를 상황 인식 기반 자동 제어에 활용한 연구는 아직 초기 단계이다.

이에 본 연구는 정적 경계 위험뿐 아니라 동적 객체의 충돌 가능성, 사용자 개인화까지 통합 분석하는 상황 인식 기반 Adaptive Passthrough¹ Framework를 제안하여 안전성과 몰입감의 균형을 갖춘 XR 경험을 제공하고자 한다.

¹Passthrough는 VR 헤드셋의 카메라를 통해 사용자가 헤드셋을 착용한 상태에서도 주변 현실 환경을 볼 수 있게 해주는 기능이다.

1.2 기존 문제점

현재의 Guardian 기반 Passthrough 시스템은 다음과 같은 한계를 지닌다.

- **경계 그리드 표시가 사전 설정된 경계선에 의존** 한다. 앞서 언급했듯, 이 방식은 협소한 공간이나 벽 인접 환경에서 정적, 동적 상황이 실시간으로 교차하는 게임 콘텐츠 등에 불필요한 간섭을 초래한다.
- **경계 제어가 수동 설정 또는 개발자 의존적 구조**에 머물러 있다. 일반 사용자가 Guardian을 완전히 비활성화하려면 개발자 모드를 별도로 활성화해야 하며[5], Meta XR Core SDK v66 이후 MR 앱에 한해 개발자가 앱 단에서 경계를 비활성화할 수 있게 되었으나[6] 이는 개발자가 앱을 별도 구성해야만 가능한 방식으로 사용자가 상황에 따라 능동적으로 제어하는 구조는 아니다.
- **상황 인식 기반의 능동적 대응이 부재**하다. 현재 시스템은 사용자의 이동 속도, 행동 패턴을 실시간 분석해 위험도를 판단하거나, 개인별 이력을 반영해 제어를 개인화하는 기능을 제공하지 않는다.

1.3 연구 목표

본 연구는 Meta Quest 3 기반의 몰입형 Extended Reality(XR) 환경에서 사용자의 안전과 몰입감을 동시에 확보하기 위한 **상황 인식 기반 Adaptive Passthrough Framework 프로토타입**을 개발하는 것을 목표로 한다.

본 시스템은 HMD의 카메라 및 센서 데이터를 실시간으로 분석하여 사용자의 이동 속도, 주변 정적 장애물, 사람과 같은 동적 객체의 움직임을 함께 판단하고 이를 바탕으로 Passthrough를 동적으로 제어한다. 나아가 사용자별 로그를 학습하는 개인화 모델을 결합하여 모든 현실 객체를 항상 노출하는 대신 위험 상황에서만 필요한 범위의 현실을 드러내는 상황 인식 (Context-aware) 기반 Adaptive Passthrough 구조를 제안한다.

1.3.1 페르소나 기반 유즈케이스 시나리오

본 연구가 제안하는 '상황 인식 기반 Adaptive Passthrough Framework'가 실제 XR 사용 환경에서 어떻게 안전성과 몰입감을 동시에 확보하는지 구체화하기 위해 두 가지 대표적인 페르소나(Persona) 및 상황별 유즈케이스를 설정했다. 기존 경계 그리드 기반 경고 방식의 한계를 보완하고, 정적 경계와 동적 경계를 독립적으로 처리하는 본 시스템의 적용 방식을 아래 그림 1와 표 1에 제시한다.




그림 1: 상황 인식 기반 Adaptive Passthrough 프레임워크의 페르소나 기반 유즈케이스 시나리오

표 1: 상황별 페르소나 및 본 시스템의 문제 해결 방안

구분	페르소나 A: 협소한 공간의 게이머 (정적 경계 대응)	페르소나 B: 공유 공간의 일반 유저 (동적 경계 대응)
프로필 및 사용 환경	[1인 가구 / 원룸 환경] 침대와 가구가 있는 비좁은 방에서 팔을 크게 움직이는 피트니스 및 액션 VR 게임을 플레이함.	[다인 가구 / 거실 환경] 가족이나 어린 자녀가 수시로 오는 넓은 거실에서 캐주얼 VR 게임을 플레이함.
기존 시스템의 한계	물리적 공간이 좁아 Guardian 경계를 작게 설정할 수밖에 없음. 사용자의 몸은 제자리에 있고 팔만 뻗는 안전한 상황임에도, 손이 경계에 가까워질 때마다 경계 그리드가 표시되어 몰입을 방해할 수 있음.	기존 Guardian은 사용자가 설정한 고정된 가상의 선(정적 경계)만 감지함. 따라서 게임에 집중하는 동안 외부인(가족)이 플레이어의 안전 구역 안으로 불쑥 걸어 들어오는 돌발 상황을 경고하지 못해 물리적 충돌 사고 위험이 높음.
본 시스템의 해결 방안 (Solution)	[국소적 표면 창 생성] 실제 충돌 위험이 감지될 때만 손끝이 향하는 벽면에 국소적인 사각형 Passthrough 창(Window)을 생성하여 불필요한 시각적 개입을 최소화함.	[사람 중심 캡슐형 창 오버레이] HMD 전방 카메라와 YOLOv9 모델을 통해 다가오는 사람의 검출 영역을 기준으로 배치한 상체 크기의 캡슐형 Passthrough 창을 가상 환경 위에 오버레이함. 사용자는 가상 세계의 몰입을 유지하면서도 다가오는 위험 요소만을 시각적으로 확인해 위험을 인지하고 대응하는 데 도움을 받을 수 있음.

위의 두 시나리오에서 보듯, 본 프레임워크는 사용자가 처한 환경(협소한 공간 vs 공유 공간)과 위협의 종류(고정된 벽 vs 움직이는 사람)를 시스템이 능동적으로 분리하여 인지한다. 이를 통해 불필요한 Passthrough 노출을 억제하여 몰입 저하를 줄이고, 실질적인 충돌 위험에는 직관적이고 국소적인 시각 정보를 제공하여 위험 인지를 지원하는 것을 목표로 한다.

제2장 연구 배경


2.1 기존 VR 안전 시스템 및 Passthrough 기술 현황

2.1.1 Meta Quest Guardian과 Smart Guardian


Meta Quest 시리즈를 비롯한 주요 VR HMD는 사용자의 물리적 충돌을 방지하기 위해 Guardian 시스템을 제공한다. Guardian Boundary는 그림 2a와 같이 사용자가 실제 공간에 가상의 안전 경계를 직접 설정하는 방식으로 구성된다. 이후 그림 2b와 같이 사용자가 설정된 경계에 근접하면 Guardian이 활성화되며, HMD의 사용자 시야에 그림 2c와 같은 시각적 경계 그리드를 표시하거나 햅틱 알림을 제공하여 사용자가 물리적 공간의 한계를 인지할 수 있도록 한다. 또한 사용 환경에 따라 Stationary 모드와 Roomscale 모드를 지원한다.



(a) Guardian 경계 영역¹



(b) 경계 접근 시 활성화¹



(c) 사용자 시야의 경계 그리드²

그림 2: Meta Quest Guardian 시스템의 경계 설정 및 경계 그리드 표시 예시

Quest 3에서는 카메라 기반 공간 인식 기능을 활용하여 주변 공간을 자동으로 스캔하고 경계 설정 과정을 보조하는 Smart Guardian 기능이 도입되었다. 이를 통해 기존의 수동 경계 설정 방식보다 편리하게 사용 가능한 공간을 인식하고 안전 영역을 구성할 수 있다.

¹출처: <https://www.inven.co.kr/webzine/news/?news=254092>

²출처: <https://arkade.com.br/arkade-vr-meta-quest-2/>

2.1.2 Passthrough 기술과 Passthrough Camera API

Passthrough 기술은 Quest 3에서 고품질 컬러 Passthrough로 본격 지원되며, Passthrough Camera API를 통해 전방 카메라에 직접 접근하여 컴퓨터 비전, ML 파이프라인을 구성할 수 있는 환경이 마련되었다[4]. 이 API는 개발자가 Quest 3, Quest 3S의 전방 컬러 카메라 스트림에 애플리케이션 단에서 직접 접근할 수 있도록 공개된 API로, 이를 통해 카메라 영상을 실시간으로 받아 객체 검출과 같은 컴퓨터 비전 파이프라인을 구성하거나 그 결과를 앱 내 로직에 반영할 수 있다[4]. 그러나 이 API는 카메라 영상 접근이라는 하드웨어 인터페이스를 제공하는 데 그치며, 그 위에서 어떤 위험을 어떻게 판단하고 언제 Passthrough를 노출할지에 대한 상황 인식 로직은 개발자가 직접 설계해야 한다. 본 연구는 이 API가 제공하는 카메라 접근성을 활용하여, 동적 객체(사람) 검출과 추적에 기반한 위험 판단 로직을 구성하는 데 이를 사용한다.

2.1.3 Apple Vision Pro의 경계 시스템

Apple Vision Pro는 Meta Quest와는 다른 방식의 안전 경계 시스템을 채택하고 있다. 사용자가 경계를 직접 설정하지 않고 시작 시점의 위치를 기준으로 고정된 영역(중심점으로부터 약 1.5 m 이상 이동 시 작동)의 시스템 경계를 자동으로 형성하며 사용자가 이 경계를 벗어나면 몰입형 경험 자체를 중단하고 외부 영상으로 즉시 전환한다[7]. 이는 깊이 센싱 기반의 공간 이해 기능을 활용한 방식이라는 점에서 Quest의 Smart Guardian과 유사한 방향성을 갖지만, 점진적 노출이 아닌 경험의 전면 중단이라는 점에서 접근 방식에 차이가 있다[8].

2.1.4 기타 플랫폼(PICO, HTC Vive) 및 공통적 한계

PICO, HTC Vive XR Elite 등 다른 주요 VR 플랫폼도 Meta Quest와 유사하게, 사용자가 직접 그린 경계에 근접하면 점진적으로 Passthrough 화면으로 전환되는 방식을 채택하고 있다. 즉 Apple Vision Pro를 제외한 대다수 플랫폼은 사용자가 사전에 정의한 경계 설정에 의존한다는 공통점을 갖는다. 이처럼 각 플랫폼은 정도의 차이는 있으나 사전에 정의된 경계까지의 거리 하나만을 판단 기준으로 삼는다는 한계를 공통적으로 공유한다.

제3장 연구 내용

3.1 본 연구의 차별성

본 연구는 앞서 2장에서 언급한 한계에 대응하여, 기존 Guardian 기반 Passthrough 시스템과 비교했을 때 다음과 같은 차별화된 접근을 제안한다.

3.1.1 위험 판단 기준

기존 Guardian은 사용자와 사전 설정된 경계선 사이의 거리에 따라 경계 그리드를 표시한다. 본 연구는 거리, 속도, TTC(충돌 예상 시간)를 각각 정규화한 뒤 가중합으로 결합한 연속적 위험도를 사용한다. 본 위험도는 경고 시작 여부를 판단하기 위한 설계 점수이다. 가중치 값들은 현재 구현에 사용한 설정값으로, 본 사용자 평가는 이 가중치 조합의 최적성을 별도로 검증한 실험은 아니다. 이를 통해 "거리는 아직 멀지만 빠르게 접근 중"이거나 "거리는 가깝지만 정지해 있는" 상황을 서로 다른 위험도로 구분할 수 있다.

3.1.2 대응 대상

기존 시스템은 공간에 고정된 벽, 가구 등 정적 경계만을 인식 대상으로 삼으며, 사람과 같이 스스로 위치를 바꾸는 대상은 판단 범위 밖에 있다. 본 연구는 공간 인식 기반의 정적 경계 분석과, 카메라 기반 사람 검출, 추적에 기반한 동적 객체 분석을 별도 파이프라인으로 두어 두 유형의 위험을 모두 인식 대상에 포함한다.

3.1.3 제어 방식

기존 Guardian은 경계 접근 여부에 따라 경계 그리드를 표시하는 방식을 사용한다. 본 연구는 위험도와 임계값 비교에 기반한 규칙 기반 로직을 기본 동작으로 유지하면서, 그 임계값 자체를 사용자별 데이터로 조정하는 ML 모델을 상위 계층에 결합한다. 즉 안전 판단의 최종 결정은 항상 규칙 기반 로직이 담당하고, ML은 그 판단 기준을 미세 조정하는 역할에 한정된다.

3.1.4 노출 범위

본 실험의 기존 Guardian 조건에서는 경계 근접 시 경계 그리드가 표시되었다. 본 연구는 위험이 감지된 표면이나 사람 주변에만 사각형 또는 캡슐형의 국소적인 창을 열어 해당 영역의 현실만 드러내며, 여러 창이 동시에 열리더라도 각 창 의 노출 강도를 개별 계산한 뒤 합성하여 나머지 시야의 몰입은 그대로 유지한다.

3.1.5 사용자 개입 필요성

기존 시스템에서 Guardian의 기본 동작 방식을 바꾸려면 개발자 모드 활성화나 앱 단의 별도 개발자 설정이 필요해, 일반 사용자가 상황에 맞게 직접 제어하기 어렵다. 본 연구는 위험 판단과 노출 결정을 시스템이 실시간으로 자동 수행하므로, 사용자가 상황별로 설정을 바꾸거나 개발자 권한을 거칠 필요 없이 상황에 맞는 반응을 얻을 수 있다.

표 2: 기존 시스템과 본 연구의 접근 방식 비교

구분	기존 시스템	본 연구
위험 판단 기준	사전 설정된 경계까지의 거리만 확인	거리, 접근 속도, TTC(충돌 예상 시간)를 결합한 연속적 위험도
대응 대상	정적 경계(벽, 가구)만 대응, 동적 위험은 대응 불가	정적 경계와 동적 객체(사람)의 위험을 함께 분석
제어 방식	경계 접근 여부에 따른 경계 그리드 표시	규칙 기반 로직을 기본 안전망으로 삼고 그 위에 ML 모델을 결합한 상황 적응적 제어
노출 범위	경계 근접 시 경계 그리드 표시	위험이 있는 영역에만 선택적, 국소적으로 노출, 나머지 시야는 몰입 유지
개인화 여부	모든 사용자에게 동일한 임계값 적용	사용자 로그 기반으로 임계값을 점진적으로 개인화(콜드스타트 → 개인화 전환)
사용자 개입 필요성	Guardian 비활성화에 개발자 모드 또는 앱 단 개발자 설정 필요	상황을 시스템이 자동으로 판단하여 제어, 별도 개입 불필요

3.2 이전 보고서 기반 설계 변경 사항

중간보고서 시점(2026년 7월)까지 본 시스템은 정적 위험도(R_{static})와 동적 위험도($R_{dynamic}$)를 아래와 같이 하나의 총위험도로 통합하여 단일 임계값과 비교하는 방식으로 설계되어 있었다.

$$R_{total} = w_{static} \cdot R_{static} + w_{state} \cdot R_{state} + w_{dynamic} \cdot R_{dynamic} + w_{intent} \cdot R_{intent} \quad (1)$$

이 구조에서는 정적 경계 분석과 동적 객체 분석이 각각 위험도 점수만을 산출하고 그 이후 “위험도 판단 → 표시 여부 결정 → 선택적 Passthrough”라는 하나의 공용 파이프라인을 거쳐 Passthrough 노출 여부가 결정되었다.

3.2.1 변경 사유

구현이 진행되면서 정적 경계와 동적 객체 두 분석 경로는 다음과 같은 근본적인 차이를 갖는다는 점이 드러났다.

- **입력 데이터의 가용성이 서로 독립적으로 변한다.** 정적 경계는 공간 인식(MRUK) 데이터에 의존하고 동적 객체는 카메라 기반 YOLO 검출에 의존한다. 한쪽 센서가 일시적으로 불안정해지거나 사용 불가능해져도 다른 쪽 판단은 영향을 받지 않아야 하는데 단일 R_{total} 로 합산할 경우 한쪽의 결측이 전체 위험도 계산에 왜곡을 준다. 또한 전문가 자문(안종길, KT 책임연구원)에서도 단순 가중평균 방식은 특정 위험 요소가 매우 높더라도 다른 위험 요소의 낮은 값에 의해 최종 위험도가 희석될 수 있다고 지적되었다.
- **반응해야 하는 시간 스케일이 다르다.** 정적 경계는 사용자가 스스로 움직여 벽에 접근하는 상대적으로 예측 가능한 상황을 다루는 반면, 동적 객체는 사람이 스스로 움직여 접근하는 상황을 다루므로 최소 유지 시간, 해제 지연 등 히스테리시스 파라미터를 서로 독립적으로 튜닝할 필요가 있다고 판단했다. 실제로 정지 장애물과 이동 장애물에 서로 다른 경고/제동 임계값을 부여하는 방식은 차량용 충돌 경고 시스템에서도 확인된다[9].

이에 따라 인터페이스를 정적/동적 각각의 독립 판단 구조로 재설계하기로 했다.

3.2.2 변경된 설계

현재 구조에서 정적 경계와 동적 객체는 위험 판단과 경고 상태를 독립적으로 처리하는 두 파이프라인으로 분리되어 있다. 일부 센서 입력과 개인화 보정치는 공유하지만, 서로의 위험 점수를 합산하지 않고 각자의 임계값과 히스테리시스로 On/Off를 판단한다. 각각은 공간상 서로 다른 위치의 독립된 창(정적 장애물 창 / 사람 창)으로 개별 렌더링한다.

각 판단 기준 임계값의 역할은 다음과 같다.

정적 임계값 3종

1. $stableOnThreshold = 0.50$ — 사용자가 정지 상태 ($UserState=0$)일 때 머리, 낮은 장애물 채널의 ON 임계값이다. 정지 상태에서는 물리적으로 갑작스러운 충돌 가능성이 낮으므로, Passthrough가 너무 쉽게 켜져 몰입을 방해하지 않도록 두 상태값 중 상대적으로 높은 쪽으로 설정되어 있다. 이 값은 단독으로 쓰이지 않고 아래 $rapidOnThreshold$ 와 함께 사용자의 연속적인 이동 상태에 따라 보간되어 실제 유효 임계값을 만든다.
2. $rapidOnThreshold = 0.45$ — 사용자가 빠르게 움직이는 상태($UserState=1$)일 때의 동일 채널(머리, 낮은 장애물) ON 임계값이다. 사용자가 실제로 이동 중일 때는 같은 위험도 점수라도 실제 충돌로 이어질 가능성이 더 크다고 보아, $stableOnThreshold$ 보다 낮게 설정해 더 낮은 위험도에서도 먼저 반응하도록 한다. 두 값의 차이(0.05)는 정지-이동 상태 간 민감도 차이의 크기를 결정하는 값이다.
3. $handFullThreshold = 0.40$ — 손 위험 ($R_{static,hand}$) 채널 전용 ON 임계값이다. 앞의 두 임계값과 달리 사용자의 이동 상태와 무관하게 고정된 값 하나만 사용되며, 손은 별도로 팔 도달 범위를 반영한 위험식을 쓰기 때문에 머리, 낮은 장애물 채널과 임계값 체계를 공유하지 않는다. 세 임계값 모두 OFF 판정은 별도 값이 아니라 각 ON 임계값에서 공통 히스테리시스 폭($hysteresisWidth = 0.08$)을 뺀 값으로 파생된다.

동적 임계값 2종

1. $onThreshold = 0.60$ — 동적(사람) 위험도가 이 값을 넘으면 Passthrough를 켜는 기준이다. 정적 임계값과 달리 사용자 자신의 이동 상태를 직접적으로 반영하지는 않고, 오직 검출된 사람의 위험도(근접, 접근속도, TTC, 경로 성분을 결합한 값)만을 기준으로 판단한다. 이때 계산에서 사용하는 접근 속도는 사용자와 사람 사이 거리의 감소율이므로 사용자 이동의 영향도 포함된다.
2. $offThreshold = 0.45$ — 위험도가 이 값 아래로 떨어지면 Passthrough를 끄는 기준이다. 정적 임계값처럼 ON값에서 히스테리시스 폭을 빼는 방식으로 파생되지 않고, ON값(0.60)과는 독립된 절대값으로 별도 지정되어 있다. ON과 OFF 사이의 폭(0.15)이 곧 이 채널의 히스테리시스 폭에 해당한다.

개인화 모듈에 대한 영향

이 설계 변경은 개인화 모듈의 산출 대상에도 영향을 주었다. 실제 기기에 적용되는 임계값 계산은 Unity 온디바이스 런타임 (`PersonalizationModels.cs`) 기준이며, 모델의 부정 확률 대리값 p_{neg} 로부터 계산한 보정치 δ (최대 0.10으로 제한)를 정적 임계값 3종($stableOnThreshold$,

`rapidOnThreshold`, `handFullThreshold`)과 동적 임계값 2종 (`DynamicOnThreshold`, `DynamicOffThreshold`) 모두에 동일하게 더하는 방식으로 다섯 임계값을 함께 조정한다. PC에서 실행되는 오프라인 학습 파이프라인(`ml-personalization`)은 이 중 정적 3종만을 계산 대상으로 다루며, 동적 2종에 대한 계산은 Unity 런타임에만 구현되어 있다.

3.3 시스템 계층별 구조 및 역할

그림 3에 제시된 전체 시스템 아키텍처는 센서 데이터 수집부터 최종 시각화까지 데이터의 흐름과 기능에 따라 총 4개의 계층(Layer)으로 구별된다. 각 계층은 역할이 명확히 분리되어 있으며, 센서 결측 시에도 시스템이 안정적으로 동작하도록 독립성을 보장한다.

3.3.1 하드웨어 및 입력 계층 (Hardware & Input Layer)

- **역할:** Meta Quest 3 HMD의 센서 어레이로부터 실시간 물리 공간 및 사용자 움직임 데이터를 수집한다.
- **주요 데이터 흐름:** RGB Passthrough 카메라 영상($1280 \times 960 @ 60\text{fps}$), HMD 및 컨트롤러의 6 DoF 공간 추적(위치, 자세, 속도) 데이터, 그리고 MRUK(Mixed Reality Utility Kit) 기반의 환경 깊이 및 공간 표면 메쉬 데이터를 상위 연산 엔진으로 전달한다.

3.3.2 이중 독립 위험 분석 엔진 (Dual Independent Processing Engine)

- **역할:** 정적 장애물과 동적 객체(사람)의 위험도를 병렬로 독립 분석하는 시스템의 핵심 연산 계층이다.
- **정적 경계 파이프라인 (Static Boundary Pipeline):** 머리, 양손, 낮은 장애물 방향으로 광선 탐침(Raycasting)을 수행하고, 깊이 표본 군집화 및 시간 평활화를 통해 정확한 거리를 계산한다. 이를 바탕으로 접근 속도와 충돌 예상 시간(TTC)을 산출하여 정규화된 정적 위험도를 구하고, 이동 상태별 임계값(θ_{stable} , θ_{rapid} , θ_{hand})과 히스테리시스를 적용해 경고 상태를 결정한다.
- **동적 경계 파이프라인 (Dynamic Boundary Pipeline):** 전방 카메라 영상에서 YOLOv9 모델로 사람을 검출하고 IoU 기반 데이터 연동을 통해 동적 객체를 추적한다. 사람 내부의 깊이 표본으로 거리를 가공한 뒤 4가지 위험 성분(근접, 접근, TTC, 경로)을 결합하여 동적 위험도를 합성하며, 초근거리 강제 표시 조건을 별도로 판정한다.




그림 3: 정적/동적 경계 파이프라인 전체 아키텍처. 하드웨어 입력부터 독립적인 두 위험 판단 파이프라인, 개인화 상위 제어, 렌더링까지의 데이터 흐름을 보여준다.

3.3.3 상위 개인화 제어 계층 (Upper Control Layer / Personalization)

- **역할:** 사용자의 누적 세션 데이터를 학습하여 정적, 동적 경계의 판단 민감도를 점진적으로 개인화하는 제어 계층이다.
- **주요 데이터 흐름:** 사용자의 세션 로그를 슬라이딩 윈도우 단위로 수집하고, 온디바이스(On-device) Random Forest 분류기를 통해 불필요한 활성화 확률을 예측한다. 구한 보정치(δ)를 2계층의 정적, 동적 판단 임계값에 반영하여, 과도한 Passthrough 개입을 억제하는 방향으로 시스템을 자동 미세 조정한다.

3.3.4 렌더링 및 출력 계층 (Rendering & Output Layer)

- **역할:** 이중 엔진에서 산출된 위험 창 매개변수를 수신하여 Unity 클라이언트 상에서 국소적 Passthrough 및 보조 피드백을 실시간 렌더링한다.
- **주요 데이터 흐름:** HMD의 좌우 눈 위치 및 투영 조건에 맞춰 공간 정렬을 수행한 후, 정적 위험 영역에는 사각형 표면 창(Rectangular Surface Window)을, 동적 사람 영역에는 상체 캡슐형 창(Capsule Window)을 오버레이하여 해당 영역의 현실만 노출한다. 아울러 바닥 안내선 시각화 및 후방 진동 피드백 등 보조 피드백을 유기적으로 결합하여 출력한다.

3.4 정적, 동적 경계의 역할과 정보 흐름

표 3: 정적 경계와 동적 경계의 역할 비교

구분	정적 경계	동적 경계
주된 대상 입력	벽, 가구, 낮은 장애물 공간 표면, 환경 깊이, 머리와 손 위치	영상에서 관측한 사람 RGB 영상, 사람 영역, 환경 깊이, 촬영 자세
평가 단위 핵심 판단 표현	머리, 왼손, 오른손, 낮은 장애물 장애물까지 거리와 신체 접근 표면 창, 바닥 안내선, 후방 진동	시간에 따라 추적한 개별 사람 사람까지 거리와 상대 접근 사람을 따라가는 상체 캡슐형 창

3.4.1 공통 처리 순서

측정 → 잡음 제거와 추정 → 위험 판단 → 경고 유지와 해제 → Passthrough 표현 순서로 처리한다. 두 경계는 위험을 독립적으로 판단하며, 최종 화면에서 표시 영역을 함께 배치한다.

3.5 정적 경계의 측정 대상과 표본 배치

머리, 손의 위치와 주변 표면을 같은 3차원 좌표에서 비교한다. 공간 인식으로 얻은 유한한 장애물 범위와 환경 깊이를 함께 사용한다.

3.5.1 수치를 읽는 기준

위험도는 0-1의 판단 점수이며 충돌 확률이 아니다. 거리, 속도는 관측에서 계산한 값이고, 기준 거리, 가중치, 유지 시간은 설계 설정값이다. 충돌 예상 시간인 TTC는 현재 접근 추세가 유지된다는 가정에 따른 추정치이다.

거리 d 의 단위는 m, 접근 속도 v 의 단위는 m/s, 시간의 단위는 초이다. 수식에서 C 는 0-1 범위 제한, S 는 변화가 부드럽게 이어지도록 하는 함수이다.

$$C(x) = \min(1, \max(0, x)) \quad (2)$$

$$S(x) = x^2(3 - 2x), \quad 0 \leq x \leq 1 \quad (3)$$

정적 경계에서도 사용자가 움직이면 위험이 달라진다. 또한 환경 깊이에 움직이는 사람이 포함될 수 있으므로 두 경계가 반응하는 대상은 일부 겹칠 수 있다.

3.5.2 입력 정보와 측정 방법

정적 경계 분석은 머리와 손이 주변의 벽이나 가구에 얼마나 가까이 있으며, 해당 장애물 쪽으로 접근하는지를 판단한다. 이를 위해 사용자의 위치, 실내 공간 정보, 환경 깊이 정보를 함께 사용한다.

표 4: 정적 경계 분석에 사용하는 입력 정보

입력 정보	얻는 방법과 활용
머리와 양손의 위치 및 방향	HMD와 컨트롤러에서 위치, 방향, 측정 시각을 얻는다. 시간별 위치 변화로 이동 속도를 계산하고, 장애물과의 거리 및 접근 여부를 판단한다.
사전에 등록된 벽과 가구	실내 공간 인식에서 장애물의 위치, 방향, 크기와 의미 분류를 얻는다. 장애물을 평면이나 상자로 표현하여 사용자와의 거리를 계산한다.
실행 중 관측한 주변 표면	환경 깊이 정보에서 지정 방향의 장애물 표면 위치, 표면 방향과 측정 신뢰도를 얻는다. 최대 탐색 거리는 6 m이다.

HMD 위치는 머리 위치로, 컨트롤러 위치는 손 위치의 대리값으로 사용한다. 따라서 손

과 장애물 사이의 거리는 컨트롤러를 기준으로 계산하며, 손 표면 전체를 직접 측정한 값은 아니다.

탐색 광선의 배치 환경 깊이 정보에서 장애물을 찾기 위해 여러 방향으로 가상의 광선인 탐침을 설정한다. 각 광선 방향의 표면을 찾아 위치와 거리를 확인하는 방식이며, 실제 빛을 발사하는 것은 아니다.

기본 균형 설정에서는 양손의 추적 대상이 모두 있을 때 머리, 왼손, 오른손, 낮은 장애물에 각각 3개씩, 총 12개의 주요 탐색 광선을 사용한다. 별도의 바닥 확인과 머리 주변 안전 영역 검사는 이 개수에서 제외한다.

표 5: 기본 균형 설정에서의 탐색 광선 배치

관측 대상	광선 배치와 목적
머리 주변: 3개	HMD 전방, 머리의 이동 방향, 전방에서 위쪽으로 10° 기울인 방향을 확인한다. 이동 속도가 기준 미만이면 이동 방향 대신 HMD 전방을 사용하므로 일부 광선은 겹칠 수 있다.
왼손과 오른손: 각각 3개	손의 이동 방향 또는 컨트롤러가 향하는 방향을 기준으로 중앙과 양쪽으로 12°씩 기울인 방향을 확인한다. 양손은 각각 독립적으로 측정한다.
낮은 장애물: 3개	이동 경로의 중앙과 좌우에 시작점을 배치하고, 수평 진행 방향에서 아래로 42° 기울여 나란히 탐색한다. 머리 높이에서 놓칠 수 있는 낮은 가구 등을 찾기 위한 것이다.

총 12개의 광선은 네 관측 영역에 각각 세 개의 탐색 경로를 확보하면서 측정 작업량을 제한하도록 구성한 것이다. 처리 부담과 관측 범위를 조절할 수 있도록 성능 우선 설정에서는 6개, 균형 설정에서는 12개, 정확도 우선 설정에서는 24개를 사용한다.

탐색 방향과 측정 조건 손 주변의 $\pm 12^\circ$ 는 기준 방향에서 양쪽으로 12°씩 벌린다는 뜻이다. 중앙 광선으로 손의 진행 방향을 확인하고, 양쪽의 보조 광선으로 그 주변의 장애물을 관측한다. 즉, 각 손에서 -12° , 0° , $+12^\circ$ 의 세 방향을 확인하며, 그 사이 공간 전체를 연속적으로 검사하는 것은 아니다. 손이 충분히 빠르게 움직이면 이동 방향을, 그렇지 않으면 컨트롤러가 향하는 방향을 기준으로 한다.

컨트롤러 자체의 간섭을 줄이기 위해 손 탐색 광선의 시작점은 탐색 방향으로 0.03m 옮기고, 최종 거리에는 이 이동량을 다시 더한다. 낮은 장애물은 수평 이동 방향을 기준으로 탐색하되, 수평 이동 속도가 0.15m/s 미만이면 HMD가 향하는 수평 방향을 사용한다.

기본 균형 설정의 공간 측정은 초당 20회(20 Hz)를 목표로 한다. 정적 및 동적 위험 판단도 각각 초당 20회를 목표로 하며, 실제 처리 빈도는 기기의 실행 상태에 따라 달라질 수 있다.

3.5.3 자기 몸과 바닥을 제외하는 원리

자기 몸의 오인 방지 손 주변의 탐색 광선이 가슴이나 배에 닿으면 자기 몸을 장애물로 잘못 인식할 수 있다. 이를 줄이기 위해 HMD 위치로 가슴 위치를 추정하고, 손 광선과 가슴을 향하는 방향의 사이각이 약 37° 이하이면 해당 광선을 제외한다.

또한 머리 아래에 몸통을 근사한 가상의 타원체를 설정한다. 중심에서 좌우 0.32m, 상하 0.50m, 앞뒤 0.24m의 반경을 가지며, 손과 낮은 장애물 탐색에서 이 영역 안의 표면점은 자기 몸으로 간주하여 제외한다. 다만 고정 크기의 근사 모델이므로 체형과 자세에 따라 자기 몸이 일부 남거나 가까운 실제 장애물이 함께 제외될 수 있다.

바닥과 낮은 장애물의 구분 별도의 아래 방향 탐색으로 바닥 높이를 추정하고, 관측한 표면의 높이와 방향을 이용해 바닥을 구분한다. 유효한 바닥 높이가 있을 때, 위쪽을 향하는 표면 중 바닥보다 높이가 0.08m 이하인 표면점은 제외한다. 수직 측면이나 바닥 높이가 불확실한 경우에는 이 조건만으로 제외하지 않는다.

0.08m는 바닥 부근의 측정 변동을 장애물로 오인하는 것을 줄이기 위해 적용한 높이 여유값이다. 모든 장애물에 적용하는 최소 높이는 아니며, 위쪽을 향하는 표면을 바닥과 구분하는데 사용한다. 다만 이 범위에 포함되는 낮은 물체의 윗면도 제외될 수 있다. 사전에 등록된 실내 공간 정보에서는 바닥과 천장으로 분류된 객체를 일반 장애물 후보에서 제외한다.

목표 빈도와 실제 처리 빈도 목표 빈도는 설정한 초당 실행 횟수로, 20Hz는 약 0.05초마다 실행하도록 설정했다는 뜻이다. 실제 달성 빈도는 실행 중 완료한 횟수를 경과 시간으로 나눈 값이며, 기기 부하에 따라 목표보다 낮아질 수 있다. 측정 실행 횟수와 유효한 관측을 얻은 횟수도 서로 구분한다.

공간 측정과 위험 판단은 별도로 실행되므로, 새 관측 전에도 보관된 최신 관측과 그 유효 상태를 이용해 경고 유지 및 해제 조건을 다시 평가할 수 있다. 따라서 위험 판단 빈도가 곧 새로운 센서 관측의 획득 빈도를 의미하지는 않는다.

3.6 정적 경계의 거리 계산과 평활화

가까운 표면을 대표 거리로 선택하고, 접근에는 빠르게 반응하면서 멀어지는 변화는 완만하게 반영한다.

3.6.1 유한한 장애물까지의 거리

머리 또는 손의 위치 p 를 장애물의 국소 좌표로 옮긴 뒤, 가로, 세로 좌표를 실제 표면 범위 안으로 제한하여 가장 가까운 점 q 를 얻는다. a 는 장애물 위치, R 은 회전, p_l 과 q_l 은 장애물 기준의 좌표이다.

$$p_l = R^{-1}(p - a), \quad q = a + Rq_l \quad (4)$$

$$d^2 = (p_x - q_x)^2 + (p_y - q_y)^2 + (p_z - q_z)^2 \quad (5)$$

첨자 x, y, z 는 공통 좌표의 각 성분이며 d 는 위 값의 0 이상인 제곱근이다. 표면 밖에서는 모서리까지의 거리도 반영한다. 3차원 장애물 체적 안에서는 거리를 0으로 두고, 유효 장애물 중 최소 거리를 선택한다.

3.6.2 깊이 표본의 군집과 시간 평활화

머리, 양손, 이동 경로별 표본을 거리순으로 정렬한다. 가까운 쪽에서 이웃 거리 차이가 0.30 m 이하로 이어지는 첫 군집을 고르고 중앙값을 대표로 쓴다. 짝수 개이면 가운데 두 값 중 더 먼 값이다.

현재 대표 거리 d_r , 이전 평활 거리 d_p , 관측 간격 Δt 로 다음 값을 구한다. 시간 상수 0.18 초는 관측의 시간적 반영 속도를 정한다.

$$\alpha = 1 - \exp(-\Delta t/0.18) \quad (6)$$

$$d_s = (1 - \alpha)d_p + \alpha d_r \quad (7)$$

$$d_f = \min(d_r, d_s) \quad (8)$$

새 표면이 가까우면 즉시 반영한다. 표면 방향이 크게 달라지거나 거리 차이가 0.75 m를 넘는 등 표면 변경이 의심되면 이력을 초기화하여 서로 다른 표면의 거리를 연속 변화로 취급하지 않는다.

표본 선택과 평활화의 결과가 부위별 대표 거리가 된다. 이후 공간 인식과 깊이의 일치 여부 및 관측 품질을 검토하여 위험 판단에 사용할 측정을 정한다.

3.7 정적 경계의 측정 결합과 신뢰도

공간 인식과 깊이의 일치 여부를 확인하고, 표본의 지지와 일관성으로 품질을 판단한다.

3.7.1 두 종류의 거리 선택

표 6: 공간 인식-깊이 결합 규칙

입력 상황	거리 선택
같은 표면이며 거리 차이 ≤ 0.35 m	두 거리 중 더 가까운 값
불일치하는 깊이가 더 가깝음	비슷한 근거리 관측을 2회 확인한 뒤 전환
깊이 거리 ≤ 0.25 m	반복 확인 없이 즉시 채택
한 종류만 유효	유효한 측정을 사용하되 새 근거리 깊이는 추가 확인
두 종류 모두 일시적으로 없음	마지막 승인값을 최대 0.25초 유지하며 신뢰도를 낮춤

같은 표면인지는 법선 방향과 평면의 위치, 범위를 비교한다. 대표 기준은 법선 내적 절댓값 0.866 이상, 평면 오프셋 0.25 m 이하이다. 일치하는 두 거리도 평균하지 않고 더 가까운 값을 선택한다.

3.7.2 깊이 관측의 품질 지표

a 는 선택 군집 표본 수를 탐침 시도 수로 나눈 비율, D 는 군집의 최대, 최소 거리 차이, n 은 평균 법선 신뢰도이다.

$$c = \exp(-D/0.30) \quad (9)$$

$$q = C((0.35 + 0.65ac)(0.50 + 0.50n)) \quad (10)$$

표본 지지가 많고 거리가 일관되며 법선이 신뢰 가능할수록 품질 점수가 높다. q 는 관측 품질 지표이며 센서 정확도나 성공 확률을 의미하지 않는다. 머리 안전 체적의 겹침이 확정되면 신뢰도 1을 사용한다.

3.8 정적 경계의 접근 속도와 TTC

3.8.1 위치 변화에서 접근 속도 구하기

머리와 손의 현재 위치 p_n , 이전 위치 p_p , 관측 간격 Δt 로 순간 속도를 계산한다. 급격한 위치 이상을 제거하고 크기를 제한한 속도를 v_l 이라 하면 평활 속도 v_f 는 다음과 같다. v_p 는 이전 평활 속도이다.

$$v_r = (p_n - p_p) / \Delta t \quad (11)$$

$$v_f = 0.65v_p + 0.35v_l \quad (12)$$

표 7: 부위별 속도 계산 허용치

부위	한 표본의 위치 변화 허용치	속도 크기 상한
머리	0.15 m	1.0 m/s
손	0.50 m	2.0 m/s

위치 변화가 허용치를 넘으면 순간 속도를 0으로 처리한다. 그 외에는 속도 크기를 제한한다. 탐침의 단위 방향 u 에 대한 내적을 이용하여 표면 쪽으로 움직이는 성분만 접근 속도로 취한다.

3.8.2 거리 감소율과 신체 움직임의 결합

d_p 와 d_f 를 직전, 현재의 위험 판단 거리라 하면, 신체 움직임에 따른 접근 v_k 와 거리 감소에 따른 접근 v_Δ 를 결합한다.

$$v_k = \max(0, v_f \cdot u) \quad (13)$$

$$v_\Delta = \max(0, (d_p - d_f) / \Delta t) \quad (14)$$

$$v = \max(v_k, \min(v_\Delta, v_k + 0.25)) \quad (15)$$

거리 감소율은 신체 움직임보다 최대 0.25 m/s 큰 범위에서 보완한다. 이력 초기화, 표면 방향 변화 5° 초과, $v_k < 0.05$ m/s 등의 경우에는 v_k 만 사용한다. 최종 상한은 2 m/s이다. 깊이 흔들림이 큰 접근 속도로 바뀌는 것을 줄이는 처리이다.

TTC는 거리/접근 속도이다. 시간 추정은 $v > 0.001$ m/s에서 가능하며, 정적 위험 수식에는 $v > 0.01$ m/s일 때만 TTC 성분을 반영한다.

3.9 정적 경계의 위험 판단

거리, 접근 속도, TTC를 함께 평가하되, 머리와 손의 움직임 특성에 맞추어 기준을 구분한다. 머리, 왼손, 오른손, 낮은 장애물의 위험은 각각 유지한다.

3.9.1 머리와 낮은 장애물

거리 위험 R_d , 속도 위험 R_v , TTC 위험 R_T 를 0-1로 정규화한다. 접근이 거의 없을 때는 R_T 를 0으로 둔다.

$$R_d = C(1 - d/1.50) \quad (16)$$

$$R_v = S(C((v - 0.05)/0.75)) \quad (17)$$

$$R_T = C(1 - TTC/2.0) \quad (18)$$

$$R = 0.45R_d + 0.30R_v + 0.20R_T + 0.01 \quad (19)$$

거리의 가중치가 가장 크며, 빠른 접근과 짧은 TTC가 위험을 추가한다. 마지막 0.01은 고정 보조 성분이다. 이 수식을 머리와 낮은 장애물에 각각 적용한다.

3.9.2 왼손과 오른손

손은 장애물까지 거리뿐 아니라 팔을 더 뻗을 수 있는 정도도 반영한다. 머리와 손 사이 거리 e 를 사용하여 남은 도달 범위 L 을 구한다. 0.75 m는 개인별 팔 길이 측정값이 아닌 고정 설계값이다.

$$L = \max(0, 0.75 - e) \quad (20)$$

$$G = C((L - d + 0.15)/0.15) \quad (21)$$

손의 거리, 속도, TTC 성분은 각각 거리 0.75 m, 속도 0.10-1.50 m/s, TTC 1.25초를 기준으로 정규화한다. 즉, 거리 성분은 $C(1 - d/0.75)$, 속도 성분은 $S(C((v - 0.10)/1.40))$, TTC 성분은 $C(1 - TTC/1.25)$ 이다.

표 8: 손 위험 결합 방식

평가	결합 방식
도달 위험	$G \times (\text{거리 성분} \times 0.35 + \text{속도 성분} \times 0.40 + \text{TTC 성분} \times 0.25)$
직접 근접 위험	$\text{거리 성분} \times 0.60 + \text{속도 성분} \times 0.25 + \text{TTC 성분} \times 0.15$
최종 손 위험	두 평가 중 더 큰 값

도달 범위가 작게 추정되어도 손 바로 앞의 장애물은 직접 근접 위험으로 반영된다. 가능한 거리가 0.25 m 이내이면 해당 부위의 위험을 1로 올린다.

3.10 정적 경계의 경고 시작과 해제

머리, 왼손, 오른손, 낮은 장애물은 각자 경고 상태를 유지한다. 켜는 기준과 끄는 기준을 다르게 하는 히스테리시스와 시간 조건으로 반복적인 깜박임을 줄인다.

3.10.1 일반 위험의 시작과 해제 기준

표 9: 정적 경계 경고 시작, 해제 기준

대상	경고 시작	해제 후보
머리, 낮은 장애물	위험도 ≥ 0.50 에서 방향성 움직임에 따라 0.45까지 감소	위험도 $\leq$ 시작 임계값 -0.08
왼손, 오른손	위험도 ≥ 0.40	위험도 ≤ 0.32

머리 속도 중 선택 위험 방향의 양의 성분을 v_{dir} 이라 하고, 정규화한 움직임을 U 라 하면 시작 임계값 θ 는 다음과 같다.

$$U = C((v_{dir} - 0.10)/0.90) \quad (22)$$

$$\theta = 0.50 - 0.05U \quad (23)$$

선택 위험 방향은 유효한 머리, 낮은 장애물 위험 중 큰 쪽을 우선한다. 위험 방향으로 빨리 이동할수록 경고가 더 일찍 시작된다. 손은 각 손의 접근 속도와 고유 기준을 사용한다.

3.10.2 최소 유지와 해제 지연

켜진 경고는 최소 1.50초 유지한다. 위험이 해제 기준 이하이거나 입력이 유효하지 않은 상태가 0.35초 연속 이어져야 해제 후보가 확정된다. 시작, 해제 기준 사이에서는 켜진 상태를 유지한다.

최소 유지와 연속 해제 후보 시간은 동시에 진행될 수 있다. 따라서 항상 1.85초를 합산해 기다리는 것은 아니다. 한 부위의 경고가 끝나도 다른 부위가 위험하면 그 경고는 계속된다.

3.10.3 머리 주변의 안전 체적과 긴급 조건

머리 주변에 안전 반경 설정 0.16 m를 이용한 회전 상자를 두고 모서리 방향의 표면 교차를 검사한다. 12개 모서리를 순환하되 한 공간 측정에 최대 4개를 확인한다. 전체 모서리를 확인한 뒤 2개 이상의 교차가 있으면 후보로 보고 반복 확인하여 겹침을 확정한다.

사용 가능한 부위별 거리 ≤ 0.25 m 또는 머리 안전 체적의 확정된 겹침이면 긴급 경고가 활성화된다. 가까운 위험은 정지 상태에서도 성립한다. 머리 체적 검사는 국소 보호 범위이며 인체 전체의 충돌 검사는 아니다.

3.11 정적 경계의 표면 창과 방향 표현

관측한 표면의 위치, 법선, 거리에서 창의 평면과 크기를 정하고, 위험이 큰 영역을 우선하여 현실을 보여준다.

3.11.1 장애물 표시 평면의 생성과 안정화

공간 인식 표면은 위치, 회전, 유한한 크기로 표시 평면을 만든다. 깊이 표본은 여러 점이 함께 지지하는 평면을 선택한다. 표본이 3개 이상이면 후보 평면을 비교하며 대표 기준은 평면 잔차 0.04 m, 법선 호환 30° , 최소 지지 비율 60%이다.

같은 표면의 법선은 시간 상수 0.20초로 평활화하고 회전을 최대 $60^\circ/\text{s}$ 로 제한한다. 25° 를 넘는 급변은 새 방향이 반복되는지 확인한다. 표본이 1-2개뿐이면 신뢰도, 법선 조건을 만족하는 작은 대체 표면을 사용할 수 있지만 방향과 크기의 불확실성이 커진다.

3.11.2 거리와 시야각으로 창 크기 결정

거리 d 에서 표시 각도 θ 를 확보하기 위한 한 변의 길이는 다음과 같다.

$$\text{길이} = 2d \tan(\theta/2) \quad (24)$$

기존 평면보다 작게 만들지 않으며 이 각도는 모든 창의 최종 크기 상한을 뜻하지 않는다. 창을 키우는 처리는 위험 판단 거리를 바꾸지 않는다.

표 10: 상태별 목표 최소 표시 각도

상태	목표 최소 표시 각도
일반	가로 24° × 세로 32°
위험 증가	가로 36° × 세로 48°까지 확대
긴급	가로 45° × 세로 60°

표 11: 정적 경계 표시 우선순위와 보조 경고

표현	배치와 전달 방식
주 표면 창	최대 2개. 긴급 여부, 위험도, TTC 위험, 접근 속도 순으로 우선한다. 일반 교체는 새 위험이 0.10 이상 높게 0.30 초 유지될 때 수행한다.
낮은 장애물 안내선	신선한 바닥 추정치가 있으면 이동 경로 위에 붉은 통로를 표시한다. 주 표면 창 2개의 개수와 별개인 추가 안내이다.
후방 방향 경고	전방 기준 120° 이상 뒤쪽에서 접근 속도 ≥ 0.075 m/s 이면 알린다. 거리 ≤ 0.25 m에서는 속도 조건 없이 경고한다.

3.11.3 표시 우선순위와 보조 경고

뒤왼쪽은 왼손, 뒤오른쪽은 오른손, 정후방 부근은 양손 진동으로 방향을 전달한다. 표시 평면을 신뢰할 수 없을 때는 화면 테두리와 진동을 대체 경고로 사용할 수 있다.

3.12 동적 경계의 영상 측정과 사람 연결

사람의 영상 영역과 신뢰도를 측정하고, 같은 사람의 관측을 시간에 따라 연결한다. 연결된 이력이 거리 변화와 상대 접근을 판단하는 기준이 된다.

3.12.1 입력 정보와 바운딩박스

표 12: 동적 경계 입력 정보

입력 또는 측정 결과	의미와 단위
RGB 영상	Passthrough 카메라의 주변 영상. 요청 조건은 1280 × 960, 최대 60 fps이며 실제 수신 조건과 다를 수 있다.
촬영 시각, 자세	촬영 시점의 시간, 카메라 위치(m)와 회전. 영상 속 사람 영역을 깊이 광선과 맞추는 기준이다.
사람 검출 영역	사람을 둘러싼 직사각형인 바운딩박스. 중심, 폭, 높이와 0-1의 검출 신뢰도를 얻는다. 검출 목표 빈도는 3 Hz이다.

검출에 사용한 영상 크기를 W, H , 픽셀 좌표의 중심과 크기를 x, y, w_p, h_p 라 하면 정규화 좌표와 면적 B 는 다음과 같다. 세로 좌표는 위에서 아래로 증가한다.

$$c_x = x/W, \quad c_y = y/H \quad (25)$$

$$w = w_p/W, \quad h = h_p/H, \quad B = wh \quad (26)$$

바운딩박스는 인체의 직사각형 근사이므로 주변 배경을 포함할 수 있다. 비정상 좌표, 크기와 거의 보이지 않는 영역을 제외하고, 크게 겹치는 검출은 신뢰도가 높은 영역을 남긴다. 중복 역제의 겹침 비율 기준은 0.45이다.

3.12.2 같은 사람의 관측을 연결하는 원리

이전 영역의 예측 위치와 현재 영역 사이의 겹침, 중심 거리, 크기 변화, 검출 신뢰도를 비교한다. 전체 연결 비용이 작아지는 대응을 선택하여 검출 순서가 달라져도 같은 사람을 이어 간다. 겹침은 교집합 면적을 합집합 면적으로 나눈 IoU로 나타낸다.

표 13: 사람 연결(추적) 확정 기준

처리	대표 기준
새 사람 연결 후보	검출 신뢰도 ≥ 0.55
기존 사람 연결 후보	검출 신뢰도 ≥ 0.35
확정	최근 5회 중 3회 관측 또는 신뢰도 ≥ 0.85 가 2회 연속
일시 미관측	연결 이력을 유지하면서 이전 위험을 점진적으로 낮춤
추적 종료	미관측 1.50초 초과 또는 누락 프레임 수 8 초과

3.13 동적 경계의 깊이 측정과 거리 가공

3.13.1 촬영 시점과 깊이 광선을 맞추는 방법

사람 내부의 표본 좌표를 정규화하고 세로 방향을 반전한 뒤 촬영 자세와 카메라 보정 정보로 광선을 정한다. 표면점과 촬영 카메라 사이의 직선거리가 표본 거리이다.

촬영 후 0.40초 초과, 움직임 표본 부족, 큰 중심, 크기 변화가 있으면 깊이 적용을 보류한다. 시점 차이 때문에 배경을 사람 거리로 취급하는 것을 줄인다.

3.13.2 사람 내부의 깊이 표본과 군집

기본 13개 표본은 위쪽부터 1, 3, 5, 3, 1개로 배치하여 중앙 몸통을 넓게 관측한다. 일부 깊이 선택 실패는 다음 관측에 5×5 의 25개로 보완한다. 유효 거리는 0.20–6.00 m이다.

영역 내부에서 가깝고 깊이도 비슷한 표본을 연결한다. 이웃 조건은 정규화 x 차이 ≤ 0.21 , y 차이 ≤ 0.18 , 거리 차이 ≤ 0.30 m이다. 모든 점을 한 번에 평균하지 않고 군집을 나누어 배경 혼입을 줄인다.

표 14: 추적용 거리와 안전 판단용 거리 비교

구분	추적용 거리	안전 판단용 거리
목적 유효 군집	안정적인 움직임과 표시 위치 표본 ≥ 3 , 거리 범위 ≤ 0.35 m, 신뢰도 ≥ 0.45	가까운 표면에 빠른 경고 표본 ≥ 2 , 거리 범위 ≤ 0.30 m, 신뢰도 ≥ 0.55
대표값 시간 가공	선택 군집의 중앙값 최근 5개 중앙값과 0.25초 평 활화	가까운 군집의 20백분위수 접근 0.08초, 이탈 0.25초 평활 화

3.13.3 군집 선택과 시간적 일관성

N 은 군집 표본 수, D 는 거리 범위, δ 는 군집 중앙값과 이전 추적 거리의 차이이다. 추적 점수는 표본 지지 a , 조밀함 c , 시간 일관성 h 를 결합한다. 이전 거리가 없으면 $h = 0.50$ 이다.

$$a = \min(1, N/6), \quad c = \exp(-D/0.35) \quad (27)$$

$$h = \exp(-|\delta|/0.50), \quad q_t = 0.45a + 0.25c + 0.30h \quad (28)$$

$$q_s = 0.65 \min(1, N/3) + 0.35 \exp(-D/0.30) \quad (29)$$

추적 거리는 높은 q_t , 안전 거리는 q_s 기준을 통과한 가까운 군집을 선택한다. 추적 거리 급변은 반복 확인하며 영상과 깊이의 변화가 충돌하면 반영을 보류한다. 안전 거리는 접근을 더 빠르게 반영한다.

3.14 동적 경계의 상대 접근과 TTC 추정

깊이가 신뢰 가능하면 거리 변화로, 부족하면 영상 속 크기 변화로 상대 접근을 추정한다. 두 결과는 물리적 의미와 신뢰도를 구분한다.

3.14.1 거리 이력에서 상대 속도 구하기

최근 1.25초의 추적용 거리와 관측 시각에 최소제곱 직선을 맞춘다. 최소 3개 표본과 0.20초의 관측 구간이 필요하다. t_i, d_i 는 각 시각, 거리이고 t_m, d_m 은 각각의 평균이다.

$$b = \frac{\sum[(t_i - t_m)(d_i - d_m)]}{\sum[(t_i - t_m)^2]} \quad (30)$$

원시 접근 속도는 $-b$ 이며 시간 상수 0.25초로 평활화한다. 거리가 줄면 양수, 멀어지면 음수이다. 이는 사람과 사용자 사이의 상대 속도이며 사람의 독립적인 보행 속도는 아니다.

표 15: 동적 경계 상태 전이 기준

움직임	상태 진입	기존 상태 유지
접근	$v \geq +0.15 \text{ m/s}$	$v \geq +0.05 \text{ m/s}$
이탈	$v \leq -0.15 \text{ m/s}$	$v \leq -0.05 \text{ m/s}$

그 사이에서는 충분한 관측이 있으면 상대 거리 유지로 본다. 거리와 영상의 움직임이 충돌하거나 관측이 부족하면 판단을 보류한다. 추적 거리 d_t 의 TTC는 $v > 0.10 \text{ m/s}$ 에서 다음과 같이 계산한다.

$$TTC_d = \min(15, d_t/v) \quad (31)$$

움직임 신뢰도는 표본 수, 관측 기간, 거리 신뢰도로 정한다. 위험 계산에서 신뢰 가능한 안전 거리와 실거리 기반 움직임이 모두 있으면 안전 거리/접근 속도로 TTC를 다시 구한다.

3.14.2 깊이가 부족할 때 영상 크기로 대체

정규화 바운딩박스 면적 B_i 의 양의 제곱근을 크기 s_i 로 보고, 관측 사이의 로그 증가율 k_i 를 구한다. 최근 1.50초, 최소 4개 표본, 최소 관측 기간 0.25초를 사용한다.

$$s_i^2 = B_i, \quad k_i = \log(s_i/s_{i-1})/\Delta t \quad (32)$$

$$k = 0.45k_p + 0.55 \text{ median}(k_i) \quad (33)$$

k_p 는 이전 평활 증가율이다. $k \geq 0.08/\text{s}$ 이면 접근, $k \leq -0.08/\text{s}$ 이면 이탈, 그 사이는 상대 거리 유지이다. 접근 중의 대체 TTC는 $1/k$ 이다.

영상 크기 기반 TTC는 자세, 가림, 카메라 회전에 영향을 받는다. 실제 거리나 3차원 속도로 취급하지 않으며, 거리 기반 결과와 불일치하면 움직임 판단을 보류할 수 있다.

3.15 동적 경계의 위험 성분과 결합

위험 판단에 사용할 거리는 신뢰 가능한 안전 거리 → 추적 거리 → 영상 크기의 거리 구간 순서로 선택한다. 가까운 표면을 먼저 반영하면서 깊이 부족에도 제한된 판단을 이어 간다.

3.15.1 네 가지 위험 성분

표 16: 동적 경계 위험 성분

성분	의미와 주요 기준
근접 P	거리 1.0/1.5/2.5/3.5 m에서 각각 1.0/0.8/0.25/0이 되도록 선형 연결한다. 1 m 이하는 1, 3.5 m 이상은 0이다.
접근 A	접근 중 속도 0.05–1.20 m/s 또는 영상 크기 증가율 0.04–0.15/s를 정규화, 평활화하고 움직임 신뢰도 ρ 를 곱한다.
TTC 성분 T	접근 상태의 유효 TTC가 2초 이하면 1, 15초 이상이면 0, 사이는 선형 변화한다.
경로 Q	화면 중심과 가까운 정도에 중심 쪽 이동 보정을 더한다. 실제 3차원 충돌 경로의 대리 지표이다.

실거리 기반 접근 성분과 TTC 성분은 다음과 같다. 접근 상태가 아니면 A 는 0이며, T 도 접근 상태에서 유효한 TTC가 있을 때만 적용한다.

$$A = S(C((v - 0.05)/1.15))\rho \quad (34)$$

$$T = C((15 - TTC)/13) \quad (35)$$

영상 기반 A 는 위 식의 속도 항을 $(k - 0.04)/0.11$ 로 바꾼다. Q 는 정규화 화면 중심까지의 거리 r 과 중심 접근률 g 를 사용하여 구한다.

$$Q = C(\max(0, 1 - r/0.50) + 0.25C(g/0.30)) \quad (36)$$

깊이가 없으면 영상 영역 면적 0.03 미만을 원거리, 0.06 미만을 중거리, 그 이상을 근거리로 본다. P 의 대체값은 근, 중, 원거리 순으로 1.00, 0.55, 0.15이며 검출 신뢰도에 따라 보정한다.

3.15.2 합성 위험과 근거리 하한

$$R_{base} = 0.55P + 0.30A + 0.10T + 0.05Q \quad (37)$$

$$R_{floor} = 0.65 + 0.25C((1.50 - d)/0.50) \quad (38)$$

실거리 $d \leq 1.50$ m이면 두 값 중 큰 값을 사용하여 접근이 작아도 근거리 위험을 유지한다. 그 외에는 기본 위험에서 움직임에 따른 감쇠를 적용한다.

실거리 1.50 m 밖의 이탈은 3.50 m까지 0.75→0.40배로 감쇠한다. 2.00 m 밖의 거리 유지, 판단 보류는 3.50 m까지 1.00→0.70배로 감쇠한다. 실거리가 없으면 이탈 점수 상한은 0.40, 거리 유지, 판단 보류의 상한은 0.55이다.

3.16 동적 경계의 경고 유지와 해제

일반 위험 임계값과 초근거리 강제 조건을 구분하여 판단한다. 여러 사람이 있으면 개별 위험의 최대값으로 전체 상태를 정하며, 표시 여부는 사람별로 판단한다.

3.16.1 일반 경고

표 17: 동적 경계 일반 경고 기준

항목	기준
경고 시작	위험도 ≥ 0.60
해제 후보	위험도 < 0.45 또는 유효 입력 없음
최소 유지	1.50초
해제 지연	해제 후보 상태가 0.35초 연속

두 시간 조건은 동시에 진행될 수 있다. 카메라를 사용할 수 있고 마지막 분석 완료 영상이 0.50초 이내이면 일반 판단의 입력을 유효하게 본다. 이는 깊이 대응에 사용하는 촬영 나이 0.40초 기준과는 목적이 다르다.

3.16.2 초근거리 강제 표시

다음 중 하나를 만족하면 해당 사람을 강제 표시 상태로 두고 경고 판단값을 1로 올린다. 잠정 관측도 확정을 기다리지 않고 경고할 수 있고, 짧은 가림 중에는 기존 강제 상태가 유지될 수 있다.

표 18: 초근거리 강제 표시 진입 조건

진입 조건	주요 기준
신뢰 가능한 안전 거리	거리 ≤ 1.00 m, 표본 2개 이상, 신뢰도 ≥ 0.55
매우 큰 사람 영역	검출 신뢰도 ≥ 0.75 , 영상 대비 높이 ≥ 0.95 , 면적 ≥ 0.65
큰 사람 영역의 반복	신뢰도 ≥ 0.60 , 높이 ≥ 0.92 , 면적 ≥ 0.55 가 2회 관측

큰 사람 영역은 화면을 거의 채우는 근접 상황의 대체 기준이다. 실제로 1 m 이내라고 측정한 결과와 구분한다.

강제 상태는 안전 거리가 2.00 m를 초과한 관측이 3회 연속 확인되어야 해제한다. 깊이가 없으면 높이 < 0.85 , 면적 < 0.45 , 신뢰도 ≥ 0.40 이며 영역이 화면 네 변에서 0.02 이상 안쪽인 상태를 3회 확인한다. 화면 밖으로 잘려 작아진 영역을 이탈로 오판하지 않기 위한 조건이다.

강제 상태가 풀려도 일반 위험이 높으면 경고는 계속된다. 한 사람의 높은 위험 때문에 모든 사람의 창이 함께 열리는 것은 아니다.

3.17 동적 경계의 사람 표시 영역

깊이 표본의 3차원 중심을 안정화한 뒤 상체 캡슐형 창을 배치한다. 표시 위치의 추정은 위험 판단용 거리와 별도로 관리한다.

3.17.1 사람 중심의 계산과 위치 보정

추적 군집의 표면점을 몸통 중심에 높은 가중치를 주어 평균하고, 먼 점의 영향을 줄이도록 가중치를 다시 조정한다. 이를 5회 반복하여 이상 표본의 영향을 낮춘다.

이전 위치 p_p 와 표시 속도 u_p 로 위치를 예측한다. 관측 중심과 예측 위치의 차이를 e 라 하면, 위치, 속도를 함께 보정한다.

$$p_e = p_p + u_p \times \Delta t \quad (39)$$

$$p_n = p_e + 0.78e, \quad u_n = u_p + 0.20e/\Delta t \quad (40)$$

표시 속도는 3 m/s로 제한하며 관측 간격이 0.75초를 넘으면 이력을 초기화한다. 표시 지연 보완용 속도는 위험 판단용 접근 속도와 구분한다.

3.17.2 상체 캡슐형 창 의 위치와 크기

바운딩박스의 위쪽 82%를 상체 기준으로 삼고 너비, 높이에 1.125배 여유를 둔다. 네 모서리의 촬영 시점 광선을 사람 중심을 지나는 평면과 만나게 하여 네 꼭짓점을 얻고, 내부에 세로 캡슐 마스크를 만든다. 평면 방향은 촬영 카메라의 전방을 기준으로 한다.

3.17.3 깊이가 없을 때의 표시 위치

실제 깊이, 최근 0.75초 이내의 위치 이력과 최대 0.50초 예측, 가정한 상체 높이 순서로 표시 위치를 확보한다. 마지막 경우에는 상하 광선 각도 θ 와 가정 높이 1.20 m로 다음 거리를 추정한다.

$$d_e = \frac{1.20}{2 \tan(\theta/2)} \quad (41)$$

일반 추정 범위는 0.60–3.00 m이며 큰 사람 영역에는 더 가까운 표시 제한을 적용한다. 가정한 신체 크기로 얻은 거리는 표시 위치에만 사용하고 위험 계산으로 되돌리지 않는다.

표 19: 사람 표시 영역의 기본 표현 조건

항목	기본 표현 조건
표시 수와 우선순위	최대 3명, 강제 표시, 높은 위험 우선
안정화와 등장	위치, 크기 0.10초 평활화, 0.125초 동안 등장
유지와 종료	마지막 적격 관측 이후 1.50초 유지 설정, 종료 시 0.30초 동안 점진적 소멸

표시 영역의 유효성은 별도로 관리한다. 위치 정보가 먼저 오래되면 경고가 켜져 있어도 창이 계속 표시된다고 보장할 수 없다.

3.18 공통 Passthrough 표현 원리

정적 표면 창과 동적 캡슐형 창은 필요한 공간만 현실로 드러내는 표시 영역이다. 두 경계의 위험 판단을 유지하면서 같은 표현 원리로 화면에 배치한다.

3.18.1 양쪽 눈에 맞춘 공간 정렬

창의 네 꼭짓점을 공통 3차원 좌표로 정하고, 현재 왼쪽 눈과 오른쪽 눈의 위치, 시선, 투영 조건에 각각 대응시킨다. 머리가 움직이면 각 눈에 보이는 창의 위치도 바뀌어 실제 공간과의 정렬을 유지한다.

사람 검출 사이에도 화면이 갱신될 때마다 현재 눈을 기준으로 재투영한다. 움직임 정보가 유효하면 제한된 시간 동안 위치를 예측하여 관측과 표시 사이의 지연을 보완한다.

3.18.2 현실 영상을 드러내는 합성

현실 Passthrough 영상 위에 가상 장면을 겹친 상태에서 창 내부의 가상 장면 색과 알파를 줄인다. 창의 중심에서는 현실을 강하게 드러내고, 가장자리에서는 노출을 부드럽게 줄인다. 경계 안쪽으로 들어온 정도를 완화 폭으로 나누어 0-1로 제한한 값을 x 라 하면 마스크 M 과 현실 노출 강도 r 을 구한다. 완화 폭의 기본값은 0.065이다.

$$M = S(x), \quad r = C(M \times \text{표시강도}) \quad (42)$$

$$\alpha_{\text{virtual}} = 1 - r \quad (43)$$

정적 창은 사각형, 사람 창은 캡슐형 경계를 사용한다. 겹친 창들의 가상 장면 잔여 비율을 곱하면 전체 현실 노출 강도는 다음과 같다. 두 경계의 위험 점수를 더하는 과정과 구분된다.

$$\text{전체노출} = 1 - \prod_i (1 - r_i) \quad (44)$$

창에서 보이는 것은 현재의 현실 Passthrough 배경이다. 사람 검출에 사용한 과거 영상을 잘라 붙이는 방식이 아니다.

3.18.3 시선을 유도하는 보조 경고

붉은 테두리와 등장 시 짧은 강조로 위험 창을 알린다. 낮은 장애물에는 바닥 안내선, 후방 위험에는 방향 진동을 사용한다. 신뢰 가능한 평면이 없으면 테두리, 진동을 대체 경고로 사용할 수 있다.

본 장에서 설명한 위험도는 관측과 추정에 기반한 위험 표현이다. TTC는 현재 추세의 가정에 의존하고, 영상 중심 기반 경로 성분은 실제 3차원 충돌 교차점을 계산한 값이 아니다.

앞서 설명한 정적/동적 창이 실제 기기에서 어떻게 나타나는지는 Figure 4에서 확인할 수 있다. 사람 주변의 캡슐형 창과 벽, 가구 방향의 사각형 창이 서로 다른 위치에 동시에, 그리고 독립적으로 열려 있는 것을 볼 수 있다.



그림 4: 실제 Quest 3 기기에서 촬영한 선택적 Passthrough 화면. 사람 주변의 캡슐형 창(동적 경계)과 벽, 가구 방향의 사각형 창(정적 경계)이 독립적으로 렌더링된 모습을 보여준다.

3.19 개인화 모듈의 전체 구조

개인화 기능은 기기 안에서 모델이 스스로 재학습되는 구조가 아니라, PC에서 미리 학습을 완료한 모델을 기기에 배포하여 추론에만 사용하는 구조로 구현되어 있다. 즉 모델을 만드는 과정과 그 모델을 실제로 사용하는 과정이 완전히 분리되어 있다.

이 구조는 크게 두 부분으로 나뉜다.

- **PC에서 수행하는 작업(오프라인, 사람이 직접 실행):** Quest에서 추출한 로그를 이용해 "이 상황에서 Passthrough를 켜 것이 실제로 필요했는지"를 판단하는 소규모 분류 모델을 학습한다. 이 작업은 개발자가 터미널에서 스크립트를 순서대로 직접 실행하는 방식으로 진행되며, 정해진 주기로 자동 실행되는 절차는 구현되어 있지 않다.
- **Quest에서 수행하는 작업(온디바이스, 실시간):** PC에서 만든 모델 파일을 Unity 프로젝트에 미리 포함해 두고, 앱이 실행되는 동안 그 모델에 최근 활성화 상황을 입력하여 "현재 Passthrough가 필요 이상으로 자주 켜지고 있는지"를 추론한다. 이 추론 결과에 따라 Passthrough가 켜지는 민감도(임계값)를 제한된 범위 내에서 조정한다.

따라서 모델이 갱신되려면, 담당자가 Quest에서 로그 파일을 추출해 PC에서 학습 절차를 다시 수행하고, 그 결과물을 Unity 프로젝트에 새로 배치해야 한다. 사용자가 앱을 사용하는 도중에 모델 자체가 변경되는 일은 없다.

그림 5은 이 전체 흐름을 보여준다.




그림 5: 개인화 모듈의 전체 흐름. ①-⑥은 PC에서 사람이 순서대로 실행하는 오프라인 절차이며, ⑦-⑧만 Quest 내부에서 실시간으로 자동 수행된다. ①-⑥을 다시 수행하지 않으면 모델은 갱신되지 않는다.

3.20 PC에서의 모델 학습

3.20.1 학습 데이터의 단위

Passthrough가 켜져 있던 하나의 연속 구간을 활성화 이벤트라고 부른다. Quest 앱은 초당 10회 현재 상태를 기록하며, 이 연속 기록에서 "켜짐 시작 시점"부터 "꺼짐 시점"까지를 찾아 하나의 이벤트로 추출한다.

이 과정에서 로그만으로는 확보할 수 없는 값이 두 가지 있으며, 이는 현재 구현의 한계로 남아 있다.

- **공간 크기**는 로그에 기록되지 않으므로, 해당 로그를 수집할 때의 방 크기를 담당자가 별도 인자로 직접 입력해야 한다.
- **수동 해제 여부**는 사용자가 Passthrough를 직접 끄는 제어 기능이 앱에 아직 구현되어 있지 않아 항상 0(해당 없음)으로 기록된다.

3.20.2 라벨링 규칙과 그 설계상 한계

모델이 학습하려는 목표는 "이 활성화가 실제로 필요했는가, 아니면 불필요하게 켜졌는가"를 판별하는 것이다. 이를 직접 관찰할 방법이 없으므로, 지속시간을 대신 사용하는 근사적 규칙을 적용한다.

$$\text{label}(e) = \begin{cases} \text{Negative} & \text{duration}(e) < \tau_{\text{neg}} \\ \text{Positive} & \text{duration}(e) \geq \tau_{\text{pos}} \\ \text{Neutral} & \text{그 외의 경우} \end{cases} \quad (45)$$

τ_{neg} , τ_{pos} 는 합성 데이터(mock)와 실제 로그(real)에서 서로 다른 값을 사용한다. 합성 데이터는 활성화가 3-15초가량 지속된다는 가정으로 설계되어 $\tau_{\text{neg}} = 2.0$ 초, $\tau_{\text{pos}} = 3.0$ 초를 사용하지만, 실제 Quest 로그를 확인한 결과 활성화 지속시간이 평균 0.17초, 최대 0.57초로 이 가정보다 훨씬 짧다는 점이 드러나, 실제 로그에 대해서는 $\tau_{\text{neg}} = 0.15$ 초, $\tau_{\text{pos}} = 0.3$ 초라는 훨씬 작은 값을 별도로 사용한다. 이 값들은 실측을 반영한 임시 조정값이며, 별도의 학술적 근거는 없이 팀 내부 판단으로 정해진 값이다.

이 규칙에는 설계상의 한계가 있다. 원래 규칙은 "사용자가 직접 꺾고 지속시간이 짧은 경우"를 Negative로 정의하려 했으나, 수동 해제 기능이 구현되어 있지 않아 이 조건은 데이터가 얼마나 쌓이든 성립할 수 없다. 이는 데이터 부족의 문제가 아니라 라벨링 규칙 자체가 성립할 수 없는 조건을 전제로 했던 설계상의 문제였다. 이에 따라 현재는 지속시간만으로 불필요 여부를 추정하는 근사적 방식으로 규칙이 수정되어 있으며, 이는 실제 사용자 의도를 직접 반영한 라벨이 아니라는 한계를 갖는다.

3.20.3 입력 특징 벡터

모델에 상황을 전달하기 위해, 최근 활성화 이벤트들을 다음 7개의 값으로 요약한다.

$$\begin{aligned} f_{pt} &= \text{최근 구간 내 활성화 빈도} \\ r_{cancel} &= \text{수동 해제 비율(현재 항상 0)} \\ \bar{t}_{pt} &= \text{평균 지속시간(초)} \\ \bar{v}_h &= \text{평균 머리 이동 속도(m/s)} \\ v_{h,\max} &= \text{최대 머리 이동 속도(m/s)} \\ A_{\text{space,norm}} &= \text{정규화된 공간 크기(0-1)} \\ T_{\text{session,norm}} &= \text{정규화된 누적 세션 시간(0-1)} \end{aligned} \quad (46)$$

3.20.4 모델 학습

7차원 특징 벡터를 입력으로 Positive/Negative/Neutral 세 범주 중 하나를 예측하는 분류 문제로 학습한다. 분류기로 Random Forest를 사용하였다[10]. Random Forest는 다수의 결정 트리를 각기 다른 부트스트랩 표본과 특징 부분집합으로 학습시킨 뒤 그 예측을 종합하는

양상블 방법으로, 개별 결정 트리보다 분산이 낮고 과적합에 강하다는 특성이 알려져 있다.

$$\text{RandomForestClassifier}(n_{\text{estimators}} = 100, \text{max_depth} = 5) \quad (47)$$

트리 개수를 100으로 설정한 것은 관련 문헌의 결과와 부합한다. Probst와 Boulesteix[11]는 트리 개수를 늘릴 때 얻는 성능 향상이 대체로 처음 100개의 트리 안에서 대부분 발생하며, 그 이후로는 추가적인 개선이 미미하다는 점을 여러 데이터셋에 대한 실험으로 보였다. 다만 이 결과는 일반적인 경향에 대한 것이며, 본 연구의 데이터에 대해 별도로 트리 개수를 바꿔가며 성능을 비교하는 실험은 수행하지 않았다.

트리 깊이를 5로 제한한 것은, 데이터 양이 적을 때 트리가 지나치게 복잡해지면 학습 데이터에만 맞고 새로운 데이터에는 일반화되지 않는 과적합이 발생하기 쉽다는 일반적 원칙에 따른 것이다. 트리 깊이가 과적합-편향 사이의 트레이드오프를 조절하는 대표적인 하이퍼파라미터라는 점은 Random Forest 하이퍼파라미터에 대한 문헌 리뷰에서도 정리되어 있다[11]. 다만 구체적으로 "5"라는 깊이 값 자체가 이 문헌에서 직접 권장하는 값은 아니며, 데이터 양이 적은 상황에서 보수적으로 선택한 값이다.

현재까지 확보한 실제 학습 데이터에는 Negative로 분류된 표본이 존재하지 않았다. 따라서 실제로 배포된 모델은 Positive와 Neutral 두 범주만을 구분하는 이진 분류기에 가까운 형태로 학습되어 있다.

3.21 Unity에서 실행 가능한 형태로의 변환

학습된 모델은 scikit-learn 라이브러리 내부에서만 실행 가능한 형태이므로, Quest에서 그대로 구동할 수 없다. 이를 위해 두 단계의 변환을 거친다.

첫 번째 단계에서는 표준 형식인 ONNX로 변환하고, 변환 전후의 예측 결과가 동일한지 검증한다. 이때 opset을 17로 고정한 것은, 현재 사용 중인 onnxruntime 버전이 더 높은 opset을 공식 지원하지 않아 로드 실패했던 사례를 경험한 뒤 정한 값으로, 팀 내부의 실무적 판단에 따른 것이다.

두 번째 단계에서는, 첫 번째 단계의 출력에 포함된 트리 앙상블 연산(TreeEnsembleClassifier)을 Unity Inference Engine이 지원하지 않으므로, 이 연산을 Unity가 지원하는 기본 텐서 연산(비교, 조건 선택, 합산, 차감)으로 직접 재구성한다. 트리가 100개라면, "이 특징값이 이 분기 기준값 이하인가"라는 비교와 그에 따른 조건 선택을 반복적으로 연결하여 같은 판단 과정을 재현하는 것이다.

이렇게 변환된 모델은 단일 출력값만 반환한다.

$$\text{risk_probability} = P(\text{Neutral}) = 1 - P(\text{Positive}) \quad (48)$$

$P(\text{Neutral})$ 을 불필요한 활성화의 확률로 대신 사용하는 것은, 학습 데이터에 Negative 표본이 없어 그 클래스 자체가 모델에 존재하지 않는 상황에서 팀이 택한 대체 설계이다. 이를 직접 뒷받침하는 학술 문헌은 없으며, Negative 클래스를 직접 학습한 확률이 아니라는 점에서 근사적 대체값이라는 한계를 가진다.

3.22 Quest 내부에서의 임계값 조정

3.22.1 조정 대상 임계값과 기본값

개인화가 조정하는 대상은 정적 경계 임계값 3종과 동적 경계 임계값 2종, 총 5개이며, 각각의 기본값은 표 20과 같다. 이 값들은 팀이 실제 기기 동작을 관찰하며 반복적으로 조정할 실측 기반 설정값으로, 특정 논문의 권고값을 따른 것은 아니다.

표 20: 개인화 대상 임계값과 기본값

임계값	기본값	의미
stableOnThreshold	0.50	정지 상태에서 머리/낮은 장애물 경고 시작 기준
rapidOnThreshold	0.45	이동 중 동일 채널의 경고 시작 기준
handFullThreshold	0.40	손 위험 채널의 경고 시작 기준
DynamicOnThreshold	0.60	동적(사람) 경고 시작 기준
DynamicOffThreshold	0.45	동적(사람) 경고 해제 기준

개인화는 이 다섯 값을 상향하는 방향으로만 조정한다. 즉, 최근 활성화가 불필요했을 가능성이 높다고 판단되면 임계값을 높여 더 확실한 위험 상황에서만 반응하도록 만든다. 반대로 활성화가 대체로 적절했다고 판단되더라도 임계값을 기본값보다 낮추지는 않는다. 이 방향성 제한은 안전 기능이 개인화로 인해 더 예민해 지는 변화보다, 덜 예민해지는 변화만 우선 허용한다는 팀의 설계 원칙에 따른 것이며다.

3.22.2 보정치 δ 의 계산

앞서 구한 risk_probability 값을 p_{neg} 라 하면, 보정치 δ 는 다음과 같이 계산된다.

$$\delta = \text{clip}\left(\max((p_{neg} - 0.5) \times 0.20, 0), 0, 0.10\right) \quad (49)$$

조정 강도(0.20)와 보정치 상한(0.10)은 모두 팀이 임의로 설정한 값이며, 학술 문헌에서 도출된 값이 아니다. 다만 두 값 사이의 수학적 관계는 확인할 수 있다. p_{neg} 의 정의역이

$[0, 1]$ 이므로 $(p_{neg} - 0.5) \times 0.20$ 의 최댓값은 $p_{neg} = 1$ 일 때 정확히 0.10이 되어, 상한이 항상 작동하는 여분 없는 제약으로 설계되어 있다.

이 수식의 동작은 다음과 같다.

- $p_{neg} \leq 0.5$ 인 경우 $\delta = 0$ 이 되어 임계값을 변경하지 않는다.
- $p_{neg} > 0.5$ 인 경우, 그 초과분에 비례하여 δ 가 증가한다. 예를 들어 $p_{neg} = 0.7$ 이면 $\delta = (0.7 - 0.5) \times 0.20 = 0.04$ 이다.
- $p_{neg} = 1.0$ 일 때 $\delta = 0.10$ 으로, 상한과 일치한다.

계산된 δ 는 다섯 임계값 모두에 동일하게 더해지며, 이렇게 더한 값이 상한값 0.95를 초과하면 해당 임계값만 0.95에서 제한된다. 동적 경계의 두 임계값(ON, OFF)에 대해서는 각각 독립적으로 계산한 δ 중 더 작은 값을 선택하여 두 임계값에 동일하게 적용한다. 이는 ON과 OFF 임계값 사이의 간격(0.15)을 항상 일정하게 유지하기 위한 처리이다.

3.22.3 추론 시점과 주기

Quest 앱은 최근 3회의 활성화 이벤트를 항상 메모리에 유지하며, 설정된 주기(기본값 5초)마다 이 이벤트들로부터 7차원 특징 벡터를 계산하고 모델 추론을 반복 수행한다.

3.22.4 콜드스타트 처리

해당 사용자의 누적 세션 수가 5회 미만인 경우에는 위의 추론 및 보정치 계산 자체를 수행하지 않고, 표 20의 기본값을 그대로 사용한다. 신규 사용자에게 데이터가 충분히 쌓이기 전까지 개인화를 보류하고 공통 기본값을 사용하는 것은 일반적으로 타당한 방향이나, 그 구체적인 기준 횟수(5회) 자체를 직접 뒷받침하는 학술 문헌은 확인하지 못했으며, 이는 팀이 설정한 임시값이다.

3.22.5 Shadow Mode: 세 가지 독립 조건

계산된 보정치가 실제로 정책에 반영되기 위해서는 표 21의 세 조건이 모두 충족되어야 한다.

표 21: 개인화 적용에 필요한 세 가지 조건

조건	기본값	의미
Shadow Mode	활성화	활성화 상태에서는 추론과 로깅만 수행하고 실제 임계값에는 반영하지 않음
Apply(적용)	비활성화	계산된 임계값을 실제 정책에 반영할지 여부
Auto Inference	비활성화	지정된 주기로 추론을 자동 반복할지 여부

세 조건이 모두 충족되어야 개인화가 실제로 작동하는데, 기본 설정 상태에서는 이 조건이 성립하지 않는다. 즉 기본 설정을 그대로 유지하는 경우, 앱은 추론과 로깅을 계속 수행하지만 실제로 임계값을 변경하지는 않는 상태로 동작한다.

3.22.6 안전장치 요약

- **Shadow Mode:** 기본적으로 활성화되어 있으며, 추론과 로깅은 계속되지만 실제 임계값에는 영향을 주지 않는다.
- **콜드스타트 게이트:** 누적 세션 수가 5회 미만인 사용자는 항상 공통 기본값을 사용한다.
- **보정치 상한(0.10)과 임계값 상한(0.95):** 한 번의 조정으로 안전 기능이 실질적으로 무력화되는 상황을 방지한다.
- **조정 방향의 제한:** δ 는 항상 0 이상으로만 계산되므로, 임계값을 기본값보다 낮추는 조정은 발생하지 않는다.
- **진단 로깅:** 매 추론마다 세션 수, 콜드스타트 여부, 사용된 특징값, 모델 출력 확률, 실제 적용된 임계값을 하나의 기록으로 저장한다.

이 안전장치들은 모두 팀이 자체적으로 설계한 것이며, 특정 논문의 방법론을 직접 따른 것은 아니다.

3.22.7 현재 구현의 한계

이 절에서 설명한 구조는 다음과 같은 한계를 가지며, 이는 향후 보완이 필요한 부분이다.

- 모델 갱신은 담당자가 로그를 수동으로 추출하여 학습 절차를 다시 실행해야 하는 오프라인 과정이며, 사용 빈도에 따라 자동으로 개선되는 지속적 학습 구조는 아직 구현되어 있지 않다.
- 학습에 사용할 수 있었던 실제 로그의 규모가 제한적이며, 특히 Negative로 분류될 표본이 확보되지 않아, 모델이 실질적으로 구분하는 것은 세 범주가 아니라 Positive 여부에 대한 이진 판단에 가깝다.
- 사용자가 Passthrough를 직접 해제하는 기능이 구현되어 있지 않아, 모델이 학습하는 "불필요함"의 기준이 사용자의 명시적인 피드백이 아니라 지속시간이라는 간접적 지표에 의존한다.

- 임계값 조정에 관련된 구체적 수치(조정 강도, 보정치 상한, 콜드스타트 기준 세션 수 등)는 학술 문헌에서 도출된 값이 아니라 팀의 실측과 판단에 따른 잠정값이며, 보다 큰 규모의 사용자 데이터를 통한 재검증이 필요하다.

제4장 연구 결과 분석 및 평가

4.1 연구 방법

본 연구는 총 12명($N=12$)을 대상으로 진행했다. 표본 크기는 동일한 안전감 척도를 사용한 선행연구인 Tseng et al. (2024) [12]의 Study 2(사용자의 안전 경계 및 장애물 근접 시 의도적 이탈 행동 연구)가 12명을 대상으로 진행된 점을 참고해 설정했다. 참여자의 평균 연령은 24.33세($SD=1.56$, 범위 22–27세)였고 여성 8명, 남성 4명이었으며 83.3%가 VR 초심자였다.

4.1.1 실험 환경


실험은 의도적으로 좁은 플레이 공간을 구성해 물리적 장애물 환경을 만들었다. 실험 시작 전, 참여자에게 VR 기기 착용 방법과 신체 움직임 시 유의사항 등 안전 안내사항을 제공했다.



그림 6: 실험 환경으로 구성한 좁은 플레이 공간

4.1.2 실험 설계

실험은 자체 제작한 사격, 회피 기반 VR 게임으로 3라운드 반복측정 (within-subjects) 설계를 사용했으며, 라운드 제시 순서는 Counterbalancing으로 통제했고 학습효과(Practice effect) 통제를 위해 본 실험 전 튜토리얼을 진행했다. 그림 7는 실험에 사용된 VR 게임의 튜토리얼 화면과 실제 게임 화면을 보여준다. 참가자는 게임 내에서 과녁을 사격함과 동시에, 날아오는 폭탄을 신체 동작으로 회피해야 한다.



(a) 튜토리얼 화면



(b) 실제 게임 화면. 참가자는 과녁을 사격하고 폭탄을 신체 동작으로 회피한다.

그림 7: 실험용 사격, 회피 기반 VR 게임

세 조건은 위험 요소를 시각화하는 방식에서 차이를 두었다. 그림 8은 Round 1의 경계선 기반 위험 인식 조건으로, 위험 영역의 경계만을 Grid Wall를 사용해 시각적으로 표시한다. 그림 9는 Round 2의 정적 위험 인식 조건으로, 고정된 위치의 위험 요소를 직사각형 윈도우로 표시한다. 그림 10은 Round 3의 정적+동적 위험 인식 조건으로, 고정된 위험 요소와 함께 움직이는 위험 요소를 각각 직사각형과 캡슐형 윈도우로 동시에 표시한다.



그림 8: Round 1 (경계선 기반 위험 인식) 조건 화면.




그림 9: Round 2 (정적 위험 인식) 조건 화면.




그림 10: Round 3 (정적+동적 위험 인식) 조건 화면.

개인화 모듈은 로그 축적을 필요로 하는 적응형 요소로, 세션이 짧고 표본이 제한적인 본 실험 조건에서는 적용이 적절하지 않다고 판단하여 통제 변인으로 제외했다. 이를 통해 개인화 영향을 배제한 채 위험 인식과 경고 표현을 포함한 시스템 조건의 효과를 검증하고자 했다.

4.1.3 측정 도구

안전감(Perceived Safety)은 Tseng et al. (2024) [12]의 Safety Boundary 척도 중 Q10–Q14, Q16 문항(신뢰, 안전감, 유용성, 경계유지 충분성, 안전유지 충분성, 성가심)으로 측정했다. 이처럼 Tseng et al. (2024) [12]의 척도 중 안전 지각 관련 문항만 선별해 사용하는 방식은 Schmelter et al. (2025) [13]의 연구에서도 동일하게 채택된 바 있다. 사용된 문항은 표 22에 제시하였다.

표 22: 안전감(Perceived Safety) 측정 문항 (Tseng et al., 2024; 7점 리커트 척도)

문항	구성 개념	문항 (한국어)	Item (English)
Q10	신뢰	나는 이 VR 안전 표시가 실제 위험(예: 주변 환경과의 충돌)으로부터 나를 지켜줄 것이라 신뢰한다.	I trust the VR safety boundaries to keep me from the physical harm (e.g., colliding with the environment).
Q11	안전감	이 안전 표시는 VR을 사용하는 동안 나를 안전하게 느끼도록 해준다.	The safety boundaries make me feel safe during my usage of VR.
Q12	유용성	이 안전 표시는 VR을 사용하는 동안 나를 안전하게 지키는 데 유용하다.	The safety boundaries are useful to keep me safe during my usage of VR.
Q13	경계유지 충분성	이 안전 표시의 경고는 VR 상호작용 중 내가 경계 상태를 유지하도록(주의를 기울이도록) 하기에 충분하다.	The warnings of the safety boundaries are sufficient to keep me alert during VR interaction.
Q14	안전유지 충분성	이 안전 표시의 경고는 VR 상호작용 중 나를 안전하게 지키기에 충분하다.	The warnings of the safety boundaries are sufficient to keep me safe during VR interaction.
Q16 [†]	성가심	이 VR 안전 표시는 나를 짜증나게(거슬리게) 한다.	The VR safety boundary makes me feel annoyed.

[†] 역코딩 문항(reverse-coded item).

몰입감(Immersion)은 IPQ(Schubert et al., 2001) [14] 문항 중 일반 현존감(General Presence) 1문항, Spatial Presence 4문항, Involvement 4문항으로 구성된 총 9문항으로 측정했다. IPQ 원문 14문항 중 1문항(SP4: 직접 행동과 외부 조작 간 대조를 묻는 문항)은 본 연구 환경에 해당하지 않는다고 판단해 제외하고 13문항을 실시했다. 이 중 Experienced Realism 하위척도 4문항은 척도 개발 과정의 요인분석 연구에서 Spatial Presence, Involvement와는 통계적으로 구분되는 별도의 요인으로 확인된 바 있어 [14], 본 연구에서는 몰입감(Presence) 점수 산출에서 제외하고 General Presence, Spatial Presence, Involvement 총 9문항의 평균으로 몰입감 점수를 산출하였다. Realism 4문항은 별도로 수집하였으며 보조 지표로 결과에서

참고용으로 보고하였다. 사용된 전체 13문항은 표 23에 제시하였다.

표 23: IPQ(Igroup Presence Questionnaire) 측정 문항 (7점 척도)

코드	하위척도	문항 (한국어)	Item (English)
G1 [‡]	일반현존감	나는 컴퓨터로 생성된 세계 안에 “실제로 있다”는 느낌을 받았다.	In the computer generated world I had a sense of “being there.”
SP1 [‡]	Spatial Presence	나는 어쩐지 가상 세계가 나를 둘러싸고 있다는 느낌을 받았다.	Somehow I felt that the virtual world surrounded me.
SP2 ^{‡, †}	Spatial Presence	나는 그저 이미지를 보고 있는 듯한 느낌을 받았다.	I felt like I was just perceiving pictures.
SP3 [‡]	Spatial Presence	나는 가상 공간에 있다는 느낌을 받지 못했다. [§]	I did not feel present in the virtual space.
SP5 [‡]	Spatial Presence	나는 가상 공간에 있다는 느낌을 받았다.	I felt present in the virtual space.
INV1 ^{†, ‡}	Involvement	가상 세계를 탐색하는 동안 주변의 실제 세계(예: 소리, 실내 온도, 다른 사람 등)를 얼마나 의식하고 있었습니까?	How aware were you of the real world surrounding while navigating in the virtual world?
INV2 [‡]	Involvement	나는 실제 환경을 의식하지 못했다.	I was not aware of my real environment.
INV3 ^{†, ‡}	Involvement	나는 여전히 실제 환경에 주의를 기울이고 있었다.	I still paid attention to the real environment.
INV4 [‡]	Involvement	나는 가상 세계에 완전히 몰두해 있었다.	I was completely captivated by the virtual world.
REAL1 [¶]	Realism (보조)	가상 세계가 당신에게 얼마나 현실적으로 느껴졌습니까?	How real did the virtual world seem to you?
REAL2	Realism (보조)	가상 환경에서의 경험이 실제 세계 경험과 얼마나 일치한다고 느꼈습니까?	How much did your experience seem consistent with real world experience?
REAL3 [¶]	Realism (보조)	가상 세계가 당신에게 얼마나 현실적으로 느껴졌습니까?	How real did the virtual world seem to you?
REAL4	Realism (보조)	가상 세계가 실제 세계보다 더 현실적으로 느껴졌다.	The virtual world seemed more realistic than the real world.

[†] 역채점 문항(reverse-coded item). [‡] 몰입감(Presence) 점수 산출에 포함된 9문항 (G1+SP1,2,3,5+INV1-4).

[§] 앵커가 “받지 못함(1)-받음(7)”으로 구성되어 있어 원 문항의 부정문 표현과 달리 역채점하지 않음. [¶] REAL1과 REAL3는 문항 문구는 동일하나(“가상 세계가 얼마나 현실적으로 느껴졌습니까?”), 응답 척도의 양 끝 라벨(anchor)이 서로 다르게 설계된 별개의 문항임. REAL1은 “현실성 정도”(완전히 현실적 ↔ 전혀 현실적이지 않음)를, REAL3는 “실제 세계와의 구분 가능성”(상상 속 세계 같음 ↔ 실제와 구분 안 됨)을 측정함.

이 외 보조 지표로 재선호도(다시 플레이하고 싶은 라운드) 문항을 사용했으며, 모든 문항은 7점 리커트 척도(1-7)로 측정했다.

4.2 분석 방법

조건 간 차이는 Friedman 검정으로 분석했다. 유의한 차이가 나타난 안전감에 대해서는 사후 Wilcoxon 검정을 실시하고, 세 쌍의 비교에 Bonferroni 기준 $\alpha = .0167$ 을 적용했다.

신뢰도는 안전감 5문항, 몰입감 9문항 각각에 대해 Cronbach's α 를 산출하여 확인했으며, 판단 기준은 Nunnally(1978)[15]의 $\alpha \geq .70$ 을 적용했다. IPQ의 Realness 하위척도 4문항은 음의 내적 일관성($\alpha = -.60$)을 보여 제외했고, 나머지 9문항(일반 현존감 1문항, Spatial Presence 4문항, Involvement 4문항)만 몰입감 점수 산출에 사용했다. 역채점 문항은 DeVellis & Thorpe(2021)[16]의 원칙(척도 최댓값+최솟값 - 원점수)에 따라 처리했으며 참여자별 라운드 점수는 해당 척도 문항들의 평균으로 산출했다. 재선호도 분포는 균등분포 가정 하의 카이제곱 적합도 검정으로 분석했다. 모든 분석은 Python(scipy, pingouin)으로 수행했다.

4.3 결과

라운드별 안전감, 몰입감의 기술통계는 Table 24와 Figure 11에 제시했다. 안전감은 Round 1에서 Round 2, Round 3로 갈수록 상승하는 경향을 보인 반면, 몰입감은 라운드 간 뚜렷한 차이를 보이지 않았다.

표 24: 라운드별 안전감, 몰입감 기술통계 (N=12)

지표	Round	<i>M</i>	<i>SD</i>	95% CI
안전감 (Safety)	Round 1	4.50	1.83	[3.33, 5.67]
	Round 2	5.45	1.28	[4.64, 6.26]
	Round 3	5.73	1.43	[4.82, 6.64]
몰입감 (Immersion)	Round 1	4.51	0.97	[3.89, 5.12]
	Round 2	4.32	0.92	[3.74, 4.91]
	Round 3	4.03	0.97	[3.41, 4.64]

Friedman 검정 결과 안전감의 라운드 간 차이는 통계적으로 유의했다 ($\chi^2(2, N=12) = 10.59, p = .005$). 효과크기(Kendall's $W = .44$)는 관례적 기준(.1=small, .3=medium, .5=large)에서 medium과 large 사이에 해당하는 수준으로, 통계적 유의성과 별개로 실질적으로도 작지 않은 차이였다. 반면 몰입감은 유의하지 않았고 ($\chi^2(2, N=12) = 2.13, p = .345$) 효과크기도 $W = .089$ 로 작게 나타나, 안전 인식 방식 고도화가 몰입감 저하로 이어진다는 근거는 확인되지 않았다(Table 25).

사후검정 결과 기존 Guardian(Round 1)은 정적 인식(Round 2), 정적+동적 인식(Round 3) 모두와 유의하게 구분됐다(각각 평균차 $-0.95, p = .005$; $-1.23, p = .004$; Bonferroni $\alpha = .0167$ 기준). 반면 Round 2와 Round 3 사이에는 평균차가 -0.28 로 앞의 두 비교보다 뚜렷하게 작았고 유의하지도 않았다($p = .141$). 즉 제안 시스템 조건에서 안전감이 높게 나타났으나, 동적 인식을 추가로 더하는 것이 정적 인식만 있을 때보다 안전감을 더 높인다는 유의한 추가 효과는 확인되지 않았다.

보조지표로는 성가심이 Round 3에서 다른 라운드보다 평균이 높게 나타났으나 통계적으




그림 11: Round별 안전감, 몰입감 평균 (N=12)

표 25: Friedman 검정 및 사후 Wilcoxon 검정 결과

지표	$\chi^2(2, N = 12)$	p	Kendall's W
안전감	10.59	.005	.44
몰입감	2.13	.345	.089

비교 (안전감)	평균차	Wilcoxon p	유의성 (Bonferroni $\alpha=.0167$)
Round 1 vs Round 2	-0.95	.005	유의
Round 1 vs Round 3	-1.23	.004	유의
Round 2 vs Round 3	-0.28	.141	비유의

로 유의하지 않았고($\chi^2(2, 12) = 4.90, p = .086$), 재선호도 역시 Round 2에 응답이 몰렸으나 유의하지 않았다 (카이제곱 적합도 검정, $\chi^2(2) = 1.50, p = .472$). 재선호도 분포를 보면 안전감이 가장 높았던 Round 3(25.0%, 3명)가 아니라 Round 2(50.0%, 6명)를 다시 선택하겠다는 응답이 가장 많아, 안전감 수치와 실제 선호가 일치하지 않는 양상을 보였다(Table 26).

종합하면, 정적 위험 인식 조건과 정적,동적 통합 인식 조건은 기존 Guardian 조건보다 안전감이 유의하게 높았으며, 이러한 안전감 향상이 몰입감의 유의한 감소와 함께 나타나지는 않았다. 한편 안전감 평균에서 몰입감 평균을 뺀 값은 라운드가 진행될수록 커졌다(Round 1: -0.01, Round 2: +1.13, Round 3: +1.70). 이는 정식 상호작용 검정을 거치지 않은 서술적 관찰이지만, 안전 인식이 정교해질수록 안전감과 몰입감의 격차 역시 함께 커지는 양상으로 해석될 여지가 있다.

표 26: 보조지표: 성가심 및 재선호도

Round	성가심 M	성가심 SD	재선호도
Round 1	2.08	1.16	25.0% (3명)
Round 2	2.25	1.36	50.0% (6명)
Round 3	3.67	2.06	25.0% (3명)

성가심: Friedman $\chi^2(2, 12) = 4.90, p = .086$ (n.s.) 재선호도: 카이제곱 적합도 검정 $\chi^2(2) = 1.50, p = .472$ (n.s.)

4.4 논의

안전감의 효과크기(Kendall's $W = .44$)는 관례적 기준에서 medium과 large 사이에 해당하는 반면, 몰입감의 효과크기($W = .089$)는 작게 나타났다. 다만 이 표본에서 얻은 효과크기 추정치는 $N=12$ 라는 소표본의 불확실성을 그대로 반영하므로, 표본을 늘렸을 때도 유의하지 않을 것이라 단정할 수는 없다. 안전감의 차이는 이 정도로 작은 표본에서도 유의하게 검출될 만큼 실질적 크기를 가진 효과였다는 점은 분명하나, 몰입감에 대해서는 효과크기가 작게 나타났다는 것 이상의 결론을 내리기는 어렵다.

한편 Round 2와 Round 3 사이에 안전감의 유의한 차이가 나타나지 않은 것은 천장효과(ceiling effect) 가능성으로도 설명될 수 있다. 두 라운드의 안전감 평균(5.45, 5.73)은 모두 척도 상단에 가까웠고 표준편차(1.28, 1.43)도 Round 1(1.83)보다 작았다. 이는 정적 인식이 도입된 시점에서 안전감이 척도의 상단에 가까워져 일종의 천장효과가 발생했을 가능성을 시사하고 이로 인해 동적 인식을 추가로 더했을 때의 개선폭을 통계적으로 포착하기 어려웠을 수 있다. 반대로 Round 1의 상대적으로 큰 표준편차는 기존 Guardian 방식에서 참여자 간 안전감 인식의 편차가 컸을 가능성을 보여준다.

정량적 결과는 참여자들의 주관적 응답과도 일치했다. Round 1에 대해 한 참여자는 “가상의 벽이 가까워졌을 때 어디 부분인지 실제로 인식을 못한다”고 답해 안전감이 가장 낮게 나타난 이유를 뒷받침했고, Round 3에 대해서는 “실제 세계가 보였기 때문에 어떤 물체인지 알 수 있어 더 안정감 있었다”는 응답이 안전감이 가장 높게 나타난 결과와 일치했다.

동시에 Round 3에서는 일부 참여자 응답에서 몰입 측면의 잠재적인 트레이드오프가 관찰됐다. 한 참여자는 “안정감은 가장 높았지만 너무 현실세계와 융합돼서 비교적 게임에 집중이 잘 안됐다”고 답한 반면, Round 2에 대해서는 “멀미도 별로 안 나고 실물도 적당히 잘 보인다”거나 “적당히 안정감을 느끼면서 가상세계에 빠질 수 있는 환경”이라는 긍정적 평가가 있었다.

이는 안전감이 가장 높았던 Round 3(25.0%)가 아닌 Round 2(50.0%)가 재선호도 조사에서 가장 많이 선택된 이유를 설명해준다. 참여자들은 안전감 자체보다 안전감과 몰입감의

균형을 재선호 기준으로 삼았을 가능성이 있으며 이는 성가심이 Round 3에서 가장 높게 (비유의하게) 나타난 결과와도 방향이 일치한다.

4.5 한계점

본 연구는 몇 가지 한계점을 지닌다.

- **표본 크기가 작다(N=12).** 이는 학부 졸업연구의 시간, 인력 제약을 고려해 유사 선행연구(Tseng et al., 2024, Study 2)[12]의 표본 크기를 참고해 설정한 것이나, 통계적 검정력이 낮아 실제로 존재하는 차이를 탐지하지 못했을 가능성을 배제할 수 없다. 특히 몰입감에서 유의한 차이가 관찰되지 않은 결과는 “차이가 없다”는 근거라기보다 “이 표본 크기로는 차이를 확인하지 못했다”는 의미로 해석될 여지가 있으며, 몰입감의 효과크기($W = .089$) 추정치 자체도 소표본에서 얻어진 만큼 불확실성이 커, 더 큰 표본에서도 동일하게 작게 나타날지는 본 연구만으로 단정할 수 없다.
- **안전감 척도의 신뢰도가 이례적으로 높게 나타났다 ($\alpha = .955$).** 이는 문항 간 개념적 중복(예: “안전하다고 느낀다”와 “안전 유지에 유용하다” 간 상관 .89-.93) 및 소규모 표본에 따른 상관관계수 추정의 불안정성에 기인할 수 있다. 지나치게 높은 α 는 문항들이 사실상 하나의 질문을 반복해서 묻은 것에 가까울 수 있음을 시사한다.
- **Round 2와 Round 3 간 안전감 차이의 미검출은 여러 해석이 가능하다.** 본문에서는 이를 천장효과 가능성으로 설명했으나, 이는 사후적으로 관찰된 평균, 표준편차 패턴에 근거한 가설이며 별도의 검정을 통해 확인된 것은 아니다. 따라서 동적 인식의 추가적 이득이 실제로 없는 것인지, 척도의 상한으로 인해 가려진 것인지, 혹은 표본 크기의 한계로 검출되지 않은 것인지를 본 연구의 결과만으로는 구분할 수 없다.
- **안전감-몰입감 격차 지표는 정식 통계검정을 거치지 않았다.** 결과에서 제시한 라운드별 격차(평균 안전감 - 평균 몰입감)는 두 지표 간 상호작용을 직접 검정한 값이 아니라 사후적으로 계산한 기술통계다. 따라서 이 격차가 라운드에 따라 실제로 유의하게 커지는지는 별도의 상호작용 분석을 통해 확인할 필요가 있다.
- **개인화 모듈은 본 실험에서 검증되지 않았다.** 시스템 설계 단계에서 제시한 개인화 모듈(사용자 로그 기반 임계값 조정)은 라운드 간 비교의 통제변인 유지를 위해 본 실험에서 제외되었다. 따라서 개인화 기능이 실제로 안전감이나 몰입감에 미치는 영향은 본 연구의 결과에 포함되지 않으며, 본 연구의 결론은 개인화가 적용되지 않은 상태의 정적/동적 위험 인식 방식에 한정된다.

제5장 결론 및 향후 연구 방향

5.1 향후 연구 방향

본 연구를 통해 정적/동적 위험 인식에 기반한 Adaptive Passthrough Framework의 기본 형태를 구현하고 사용자 평가를 수행했으나 실제 활용 가능한 프레임워크로 발전시키기 위해서는 다음과 같은 보완이 필요하다.

- **멀티모달 피드백으로의 확장** — 현재 프레임워크는 시각적 Indicator(부분적 현실 화면 노출)와 후방 방향 진동을 안전 신호로 제공한다. 3D Spatial Audio와 추가적인 Haptic Feedback 패턴을 프레임워크의 경고 표현 계층에 도입하여, 상황에 따라 시각, 청각, 촉각 신호를 조합해 제공할 수 있도록 표현 방식을 다변화할 필요가 있다.
- **배포 가능한 형태로의 발전** — 현재 프레임워크는 연구용 프로토타입 형태로 구현되어, 특정 개발 환경에서 빌드하여 실행하는 수준에 머물러 있다. 실제 사용자가 설치하여 쓸 수 있으려면 앱 형태의 패키징, 설정, 권한 안내 UI, 호환성 검증 등 배포에 필요한 요소를 갖추는 과정이 추가로 필요하며 이를 통해 프레임워크를 실험용 시스템에서 실사용 가능한 애플리케이션으로 발전시킬 필요가 있다.

5.2 결론

본 연구는 기존 VR HMD의 Guardian 기반 안전 시스템이 갖는 두 가지 한계, 즉 사전 설정된 경계선까지의 거리만으로 판단하는 이진 제어 방식과 모든 사용자에게 동일한 기준을 적용하는 획일적 반응 방식에서 출발했다. 이를 보완하기 위해 정적 경계와 동적 객체의 위험을 각각 연속적인 위험도로 평가하고, 필요한 영역에만 현실 영상을 선택적으로 노출하며, 사용자 로그를 반영해 반응 민감도를 점진적으로 조정하는 상황 인식 기반 Adaptive Passthrough Framework를 설계하고 구현했다.

시스템은 정적 경계 파이프라인과 동적 경계 파이프라인을 완전히 독립된 구조로 두어, 거리, 접근 속도, TTC를 결합한 정적 위험도와 검출, 추적 기반의 동적 위험도를 각자의 히스테리시스로 판단하도록 했다. 이 독립 구조는 중간보고서 시점까지의 단일 가중합 방식이

가진 구조적 한계, 즉 한 위험 요소의 결측이나 극단값이 다른 요소에 의해 희석될 수 있다는 문제를 해결하기 위해 채택한 설계이며, 정적 3종, 동적 2종의 임계값을 온디바이스 개인화 모듈이 조정하도록 구현했다.

12명을 대상으로 한 사용자 실험 결과, 위험 인식 방식을 기존 Guardian 방식에서 정적 인식으로, 다시 정적+동적 인식으로 고도화할 수록 안전감은 통계적으로 유의하게 상승했으며(Kendall's $W = .44$), 이 과정에서 몰입감의 유의한 저하는 관찰되지 않았다. 이는 안전 기능의 강화가 몰입 경험과 반드시 상충하지 않을 수 있음을 시사하는 결과로, 본 연구가 제안한 선택적 노출 방식의 핵심 가정을 뒷받침한다. 다만 동적 인식을 추가로 더하는 것이 정적 인식만 있을 때보다 안전감을 유의하게 더 높인다는 근거는 확인되지 않았고, 재선호도 조사에서는 안전감이 가장 높았던 조건이 아니라 안전감과 몰입감의 균형이 더 나은 조건이 가장 많이 선택되어, 사용자들이 안전감 자체보다 두 경험 사이의 균형을 더 중요하게 고려할 수 있음을 보여주었다.

동시에 본 연구는 몇 가지 명확한 한계도 갖는다. 표본 크기가 작아 몰입감을 비롯한 일부 지표의 검정력이 제한적이었고, 개인화 모듈은 라운드 간 비교의 통제변인 유지를 위해 이번 실험 범위에서 제외되어 실제 사용자 데이터에 대한 검증이 이루어지지 않았다. 개인화 모듈의 학습, 배포 파이프라인 자체는 온디바이스 추론까지 포함해 구현되어 있으나, 실제 사용자 로그가 아닌 제한된 데이터로 운용되고 있어 이를 실제 데이터로 검증하는 작업이 이어져야 한다. 또한 시각적 신호에 한정된 안전 표현을 다른 감각 양식으로 확장하고, 다양한 물리적 환경에서의 강건성을 확보하며, 연구용 프로토타입을 실제 배포 가능한 형태로 발전시키는 과제가 남아 있다.

이러한 한계에도 불구하고, 본 연구는 정적, 동적 위험을 연속적인 지표로 통합 판단하고 필요한 영역에만 현실을 노출하는 접근이 이진적인 기존 방식 대비 안전성과 몰입감의 균형을 개선할 수 있는 실현 가능한 대안임을 실증적으로 보였다는 데 의의가 있다. 향후 개인화 모듈의 실데이터 검증과 멀티모달 확장, 배포 가능한 형태로의 발전이 이루어진다면, 본 프레임워크는 몰입형 XR 환경에서 안전과 몰입을 함께 고려하는 실용적인 안전 시스템으로 자리매김할 수 있을 것으로 기대한다.

제6장 기타

6.1 개발 일정 및 역할 분배

본 연구는 2026년 5월부터 9월까지 약 5개월간 진행되었으며 설계, 구현, 검증의 세 단계로 나누어 수행했다.




그림 12: 연구 개발 일정

팀원	담당 역할	세부 내용
따다소 (팀장)	개인화 모델 개발 및 사용자 실험 연구 진행	• Random Forest 기반 On-device 로그 수집, 추론 파이프라인 구축 및 구현 • 사용자 로그를 사용한 PC 기반 개인화 모델 재학습 파이프라인 구현 및 배포 • 사용자 실험 설계, 진행 및 비모수 통계 분석 • 보고서 작성 및 발표 자료 제작
최아영	정적 경계 기반 위험도 알고리즘 및 실험용 게임 개발	• 정적 경계 기반 충돌 위험도 알고리즘 설계 및 구현 • 정적 위험도에 따른 Passthrough 제어 로직 구현 • 실험용 VR 게임 개발 및 실험 조건별 위험도 시스템 연동
이승주	Quest 3 기반 동적 위험 인식 및 안전 시스템 통합	• 카메라, 깊이 정보를 활용한 사람 검출, 추적 및 접근 위험도 계산 기능 구현 • 위험 위치에 따른 선택적 Passthrough 시각화와 시각, 진동 피드백 구현 및 안정화 • 개인화 모델 및 실험용 VR 게임과 위험도 기반 안전 시스템 통합

참고문헌

- [1] 김성진. 확장현실(xr) 산업의 현황과 과제. Kiet 산업경제, 산업연구원(KIET), 2023.
- [2] Development and validation of the collision anxiety questionnaire for vr applications. In *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, 2024.
- [3] Meta. Meta quest에서 패스스루를 사용하는 방법, n.d.
- [4] Meta for Developers. Passthrough camera API overview. Meta Horizon Documentation, <https://developers.meta.com/horizon/documentation/spatial-sdk/spatial-sdk-pca-overview/>, December 2025.
- [5] ArborXR. How to disable the boundary on meta quest devices. <https://help.arborxr.com/en/articles/8638529-how-to-disable-the-boundary-on-meta-quest-devices>, 2024.
- [6] Meta Platforms, Inc. Create engaging experiences with anchoring improvements and multi-room support. Meta Horizon Developer Blog, <https://developers.meta.com/horizon/blog/v66-multi-room-support-spatial-anchors-api-improvements-quest-developers/>, July 2024. Published: 2024-07-11; Accessed: 2026-09-13.
- [7] Apple Inc. Important safety information for Apple Vision Pro, 2024. Accessed 2026-09.
- [8] UploadVR. Apple explains vision pro's VR playspace boundaries, September 2023. Accessed 2026-09.
- [9] Ran Meng, Hua Chai, Yanqiu Xia, Zhe Wang, Yong Jia, Hui Cai, and Chuanbin Feng. Vehicle braking and warning method, system and device based on binocular stereo camera, August 2023.
- [10] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

- [11] Philipp Probst, Marvin N. Wright, and Anne-Laure Boulesteix. Hyperparameters and tuning strategies for random forest. *WIREs Data Mining and Knowledge Discovery*, 9(3):e1301, 2019.
- [12] Wen-Jie Tseng, Panagiotis D. Kontrazis, Eric Lecolinet, Samuel Huron, and Jan Gugenheimer. Understanding interaction and breakouts of safety boundaries in virtual reality through mixed-method studies. In *2024 IEEE Conference on Virtual Reality and 3D User Interfaces (VR)*, pages 482–492. IEEE, 2024.
- [13] Thereza Schmelter, Paul Küchenmeister, Jürgen Geuter, and Kristian Hildebrand. Depth-aware immersive visualization of boundaries using particles in VR. In *Proceedings of the 2025 ACM Symposium on Spatial User Interaction (SUI '25)*. Association for Computing Machinery, 2025.
- [14] Thomas Schubert, Frank Friedmann, and Holger Regenbrecht. The experience of presence: Factor analytic insights. *Presence: Teleoperators and Virtual Environments*, 10(3):266–281, 2001.
- [15] Jum C. Nunnally. *Psychometric Theory*. McGraw-Hill, 2nd edition, 1978.
- [16] Robert F. DeVellis and Carolyn T. Thorpe. *Scale Development: Theory and Applications*. SAGE Publications, 5th edition, 2021.